통계학

- 기술 통계 -

2026_Spring

조상구

- **통계학 (Statistics) 이란?**

  - **자료의 수집 방법 (Sampling)**

  - **자료의 표현 및 요약 방법**
    (기술 통계학; descriptive statistics)

  - 자료로부터 일반적인 성질을 끄집어 내는 방법
    (추론 통계학; inferential statistics)

Data 분석 과정

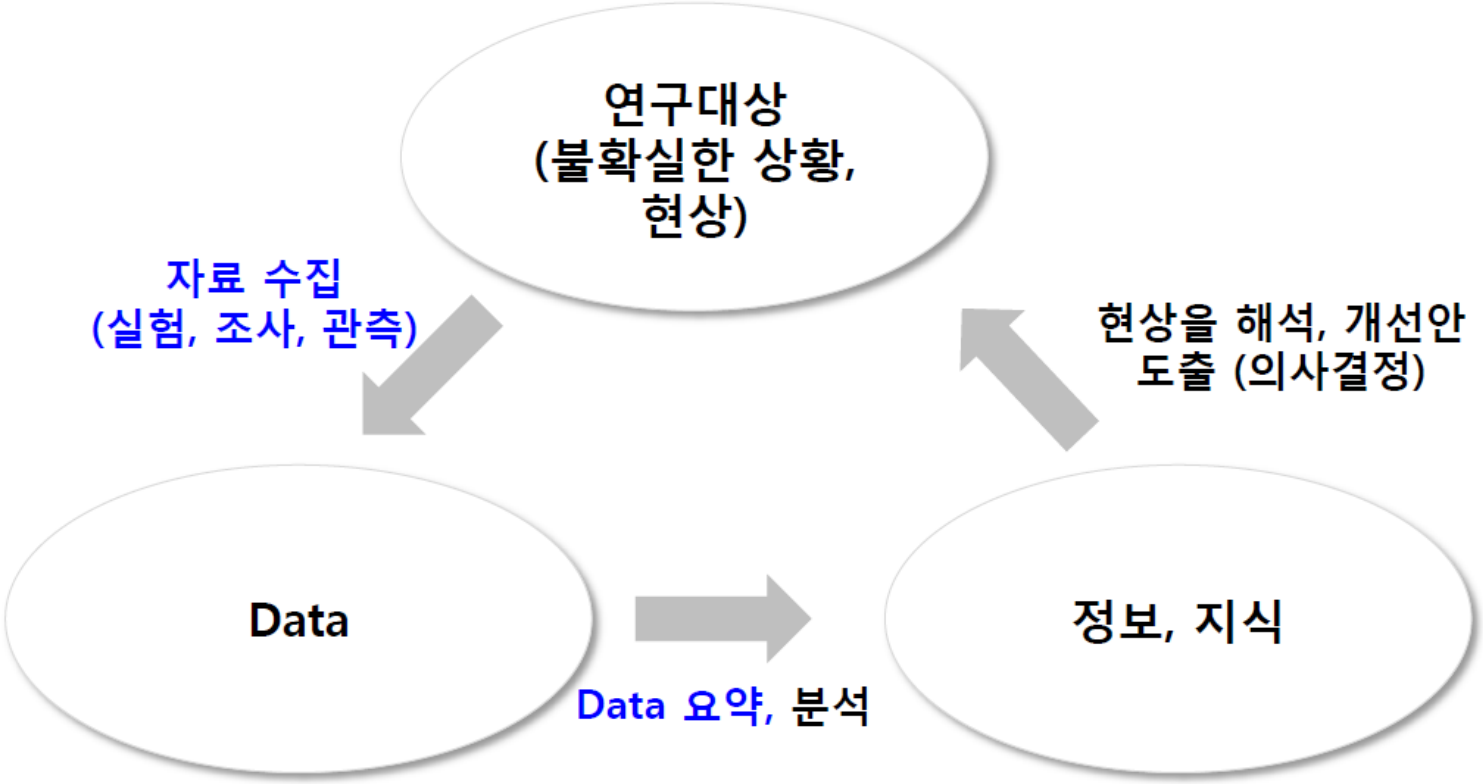
연구대상
(불확실한 상황,
현상)
자료 수집
(실험, 조사, 관측)
Data
Data 요약, 분석
정보, 지식
현상을 해석, 개선안
도출 (의사결정)

- 전수조사(Census)
- 표본조사(Sampling)

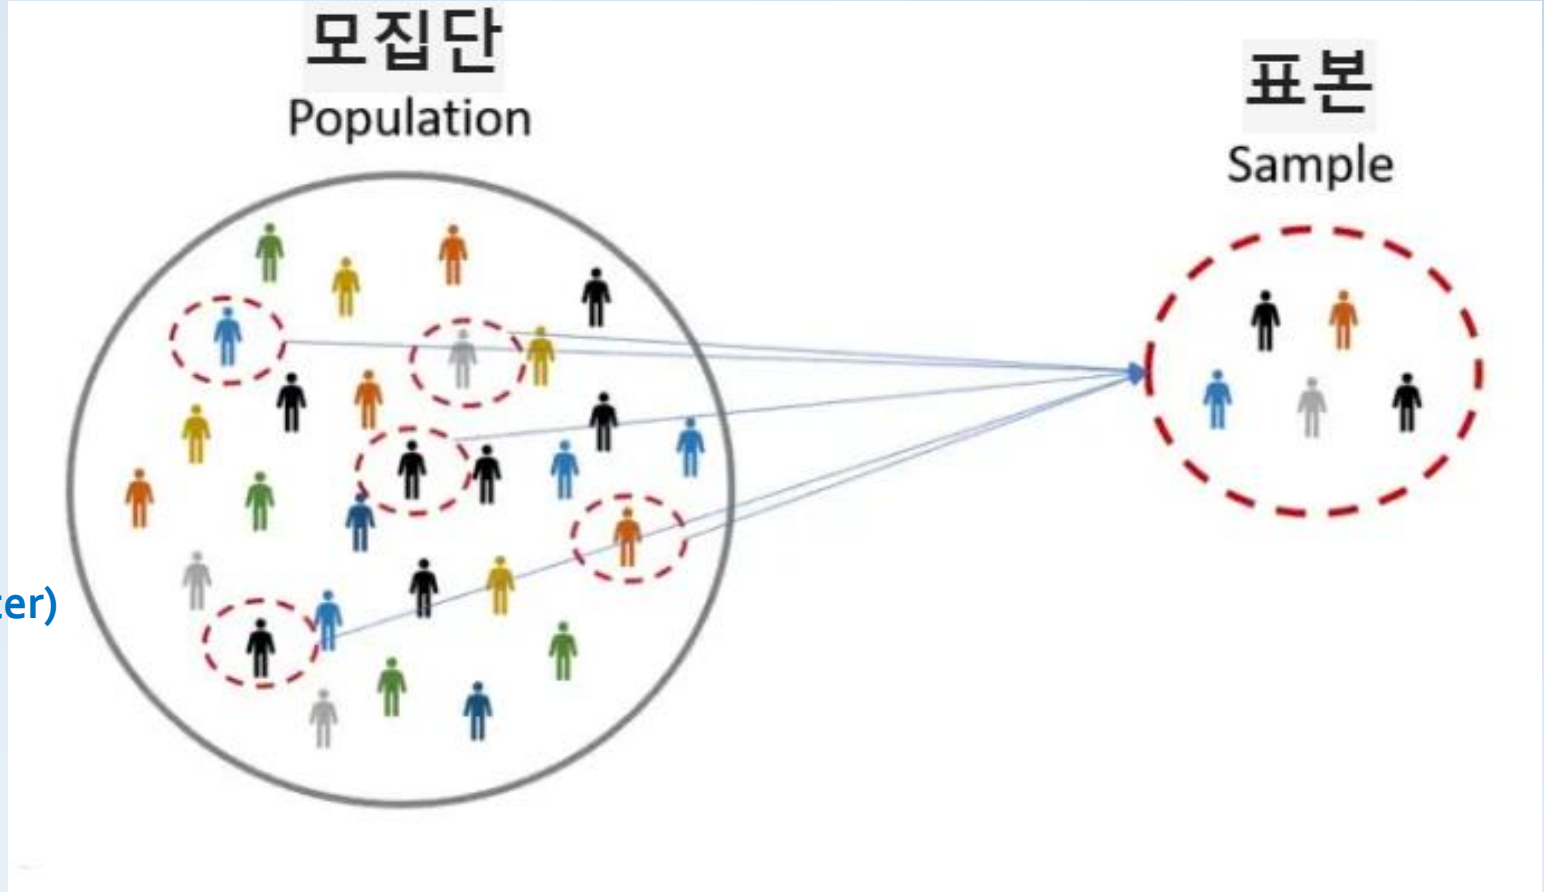

모수(parameter)
- 모집단평균
- 모집단분산

모수(parameter)
- 표본평균
- 표본분산등

Sampling (1/3)

- **단순무작위추출법 (simple random sampling)**
  - 모집단의 모든 대상이 표본으로 선택될 확률이 동일한 추출방법
  - 다른 추출법의 기본이 되는 추출법
  - 모집단에 대한 사전 정보가 없는 경우 사용
  - 난수표 사용
  - **실습: 어떤 소비자 단체에서 담배의 니코틴 함유량을 조사하고자 한다. 100개의 모집단에서 임의로 10개의 sample을 단순무작위추출법을 이용해 sampling 해보자**

    ※ Tip) Excel 의 rand() 함수, roundup() 함수 사용

Sampling (2/3)

- **층화무작위추출법 (stratified random sampling)**
  - 모집단이 특정 기준에 따라 동질적인 몇 개의 집단으로 분류하고, 각 집단에서 무작위로 표본을 선택하는 방법
  - 집단의 특성을 모두 반영해야 하는 경우에 사용
  - 집단간의 성격이 이질적이나, 집단 내 대상간의 성격은 동질적이라고 가정
  - **실습: 어떤 소비자 단체에서 담배의 니코틴 함유량을 조사하고자 한다. A회사의 담배가 70개, B회사의 담배가 30개가 있다. 10개의 sample을 층화무작위추출법을 이용해 선택해보자**

균등 층화,
비례 층화

Sampling (3/3)

- **집락추출법 (cluster sampling)**
  - 모집단이 여러 개의 집단으로 구성되어 있는 경우, 전체 집단 중 일부를 무작위로 선택한 뒤, 선택된 집단 모두를 표본으로 조사하는 방법
  - 집단간의 차이는 동질적, 집단내의 차이는 이질적이라고 가정함
  - 예) 고등학교 학생들의 몸무게 조사

문제 풀이

❖ seaborn의 tips 를 모집단으로 가정하고 tip 변수의 값(데이터) 분포, 평균과 분산을 설명하라

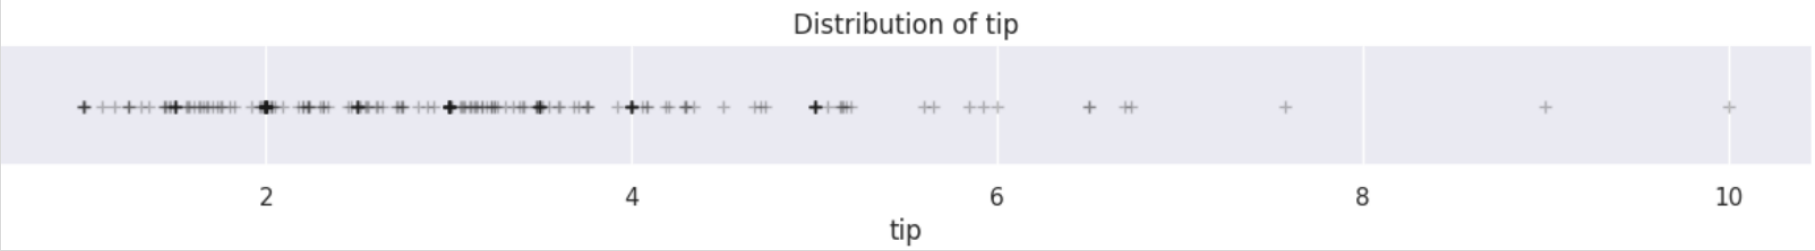

❖ 평균의 함정(the pitfall of mean)

❖ seaborn의 tips 모집단에서 3가지 표본추출방법을 파이썬 코드로 제시하라

❖ 3가지 표본과 모집단과의 평균과 분산을 비교한 후 어떤 표본추출방법이 가장 적합한지 토론하라

https://www.mt.co.kr/opinion/2019/04/09/2019040811152977932

통계 Data의 종류

명목형 (nominal)

- 어떤 대상에 숫자나 기호를 부여하여 구분하기 위해 사용
- 크기나 순서가 의미 없음
- 혈액형, 이름

서열형 (ordinal)

- 기준에 따라 대상을 서열화하여 숫자나 기호를 부여
- 순서가 의미 있으나 크기는 의미없음
- 품질등급, 학점, 올림픽 메달

구간형 (interval)

- 대상들간의 상대적인 차이를 비교하는데 사용 (비율은 의미가 없음)
- 온도

비율형 (interval)

- 수치 자체가 실제적인 수량적 의미를 가짐
- 판매량, 무게

문제 풀이

❖ https://github.com/ancestor9/data/blob/main/customers.csv 의 데이터를 데이터셋으로 읽은 후 컴퓨터가 인식할 수 있도록 모든 데이터를 수치화하는 데이터전처리(Data Preprocessing)를 수행하라

Preview | Code | Blame 10001 lines (10001 loc) · 641 KB

```csv
고객ID,성별,결제수단,거주지,회원등급,만족도,최근접속시간(시),선호제품군_적정온도,나이,구매수량,총결제금액
CUST_0001,남성,휴대폰결제,대구,Gold,2,1,27.0,34,7,760355
CUST_0002,여성,계좌이체,대구,Gold,5,15,24.6,20,42,727001
CUST_0003,여성,신용카드,광주,Gold,1,6,20.3,51,8,618787
CUST_0004,여성,계좌이체,서울,VVIP,5,20,16.8,19,29,434545
CUST_0005,여성,계좌이체,광주,Gold,3,6,23.5,53,45,604750
CUST_0006,기타,계좌이체,경기,Gold,4,22,22.0,22,18,554530
CUST_0007,남성,간편결제,광주,VIP,1,3,24.5,41,11,83149
CUST_0008,여성,신용카드,대구,VIP,3,10,23.2,70,37,523660
CUST_0009,여성,신용카드,대구,Bronze,2,12,25.2,25,36,58966
CUST_0010,여성,간편결제,부산,VVIP,2,15,17.3,27,49,792361
CUST_0011,기타,휴대폰결제,부산,VVIP,5,16,26.6,54,8,431520
CUST_0012,기타,간편결제,서울,Gold,1,22,21.0,64,39,890029
```

Data 요약 및 표현

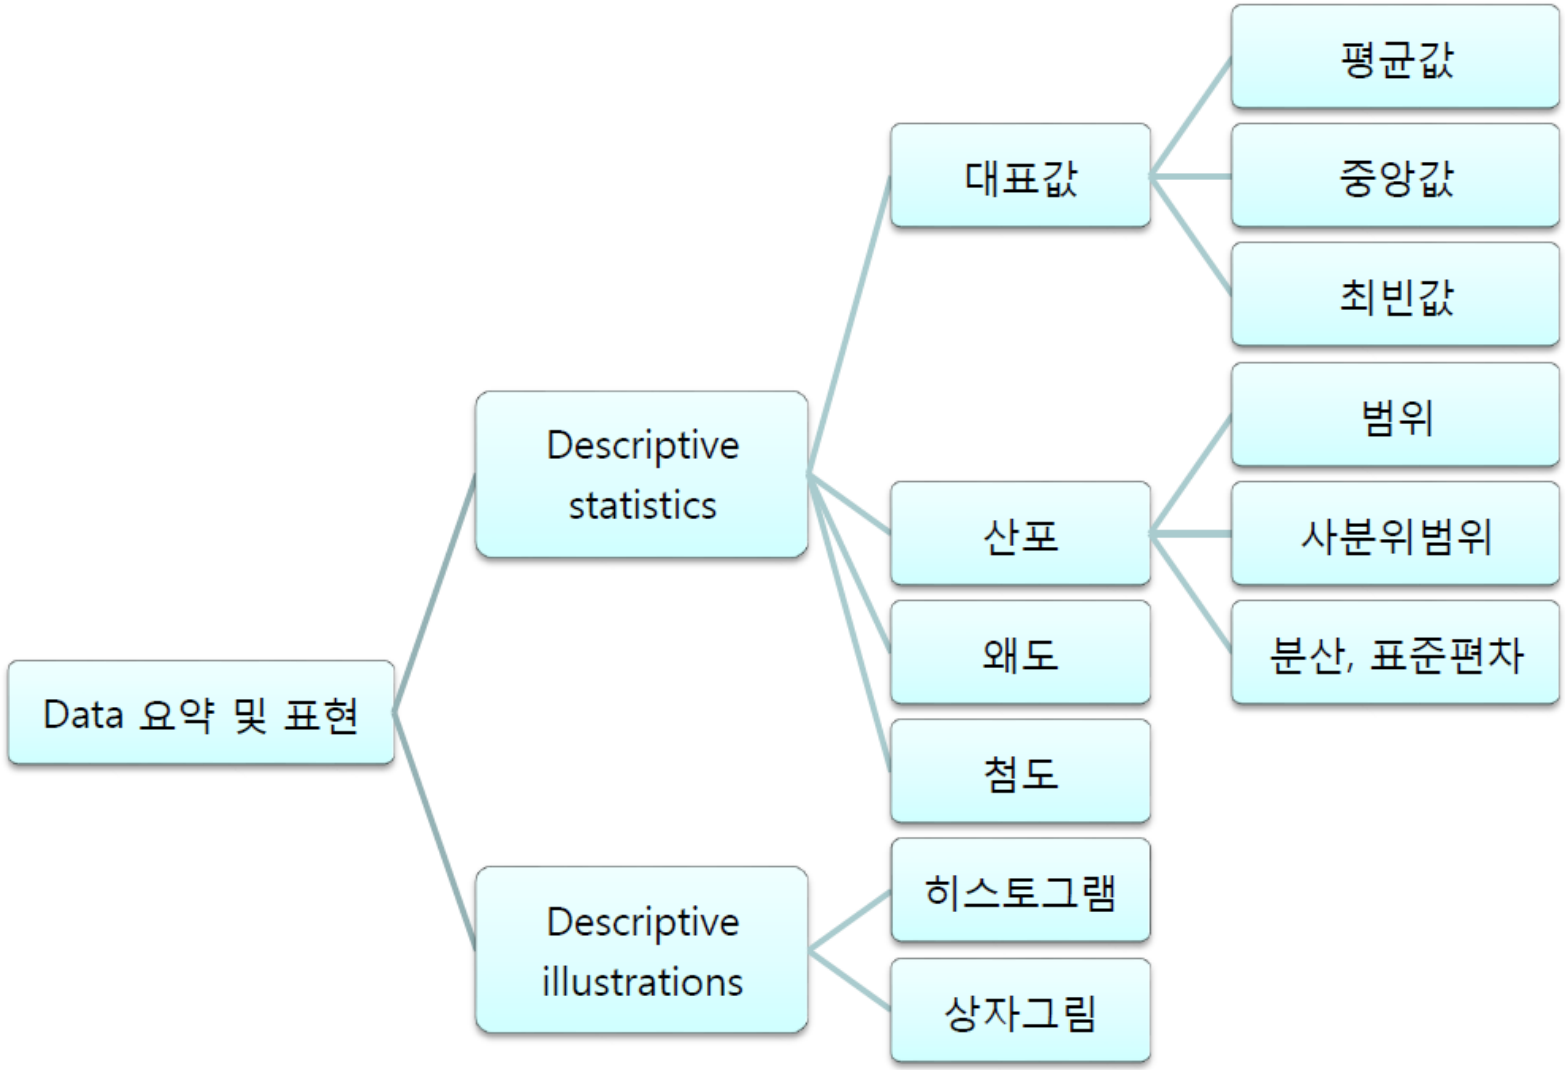
Data 요약 및 표현
Descriptive statistics
Descriptive illustrations
대표값
산포
왜도
첨도
히스토그램
상자그림
평균값
중앙값
최빈값
범위
사분위범위
분산, 표준편차

Descriptive Statistics: 대표값

- **평균 (mean)**
  - 자료값들의 합(sum)을 표본 크기(관측치의 개수) n으로 나눈 것, 일반적으로 가장 널리 쓰이는 대표값
  - 극단적으로 크거나 작은 값 (outlier) 에 민감
  - Ex) 500, 489, 495, 493, 505, 248 → $\frac{500 + 489 + 495 + 493 + 505 + 248}{6} = 455$

평균의 함정

- **중앙값 (median)**
  - 자료값들을 크기 순으로 정렬하였을 때 중앙에 위치하는 값, 평균에 비해 극단적으로 크거나 작은 값 (outlier) 에 민감하지 않음
  - Ex) 500, 489, 495, 493, 505, 248 → median = 494

- **최빈값 (mode)**
  - 자료값들 중 가장 빈도가 많은 자료값

Descriptive Statistics: 산포 (1/2)

- **범위 (Range)**
  - 최대값과 최소값의 차이
  - 극단적으로 크거나 작은 값 (outlier) 에 민감
  - Ex) 500, 489, 495, 493, 505, 248 → range = 257

- **사분위 범위 (Inter-quartile range; IQR)**
  - 사분위수 (quartile): 데이터를 크기순으로 나열하여 4등분 할 경우, 4등분되는 위치에 해당하는 값
    - Q1: 제1사분위수, 25%백분위수 (데이터의 25%에 해당하는 값)
    - Q2: 제2사분위수 (=중앙값), 50%백분위수 (데이터의 50%에 해당하는 값)
    - Q3: 제3사분위수, 75%백분위수 (데이터의 75%에 해당하는 값)
    - Ex) 1,2,3,4,5,6,7,8,9,10
      - Q1 = 3
      - Q2 = 5.5
      - Q3 = 8
    - 사분위 범위: Q3-Q1

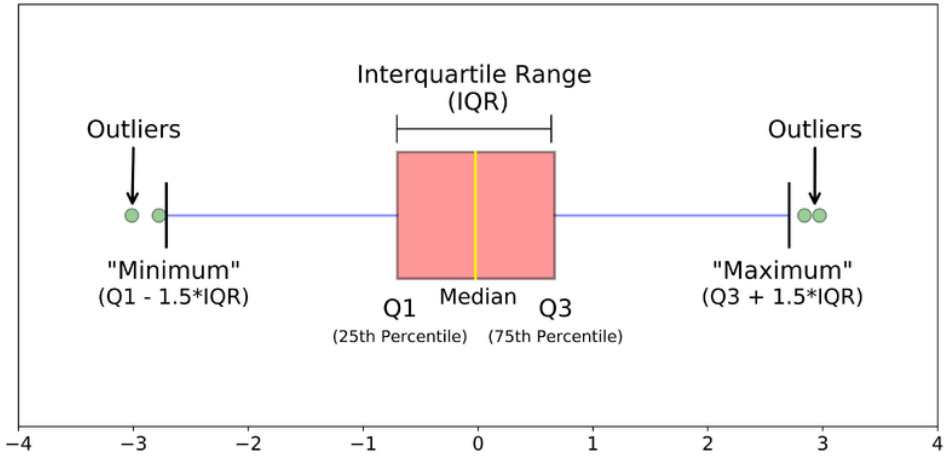

Descriptive Statistics: 산포 (2/2)

- **분산 (Variance)**
  - 각 데이터들이 평균으로 부터 얼마나 떨어져 있는지 표현

$$s^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}$$

  - Ex) 500, 489, 495, 493, 505, 248

$$s^2 = \frac{(500-455)^2 + (489-455)^2 + (495-455)^2 + (493-455)^2 + (505-455)^2 + (248-455)^2}{5} = 10314.8$$

- **표준편차 (Standard deviation)**
  - 분산에 제곱근을 취한 것으로 산포의 척도로 가장 널리 쓰임
  - $s = \sqrt{s^2}$
  - Ex) 500, 489, 495, 493, 505, 248 → s = 101.6

Descriptive Illustrations: Histogram (1/4)

- **히스토그램 (Histogram)**
  - 도수분포표에서 각 구간별 관측도수를 막대형태로 표현한 그래프
  - 도수분포표: 전체 data 범위를 구간으로 분할하고, 각 구간에 포함되는 데이터의 도수(개수)를 산출한 표
  - Histogram 작성 순서
    1. 구간 수 결정
    2. 구간 폭 결정 (구간폭 = 범위 / 구간수)
    3. 구간 경계치 결정
    4. 구간별 도수 산출
    5. Histogram 표현

Descriptive Illustrations: Histogram (2/4)

- **Example) 여대생 신장 자료**

170	151	154	160	158	154	171	156	160
157	160	157	148	165	158	159	155	151
152	161	156	164	156	163	174	153	170
149	166	154	166	160	160	161	154	163
164	160	148	162	167	165	158	158	176

1. 구간 수 결정 8
2. 구간 폭 결정 3.5 (= (176-148)/8)
3. 구간 경계치 결정 151.5, 155, 158.5, ..., 176
4. 구간별 도수 산출 5, 7, 9, ..., 2
5. Histogram 표현

도수 분포표

구간	도수
151.5	5
155	7
158.5	9
162	10
165.5	6
169	3
172.5	3
176	2
Total	45

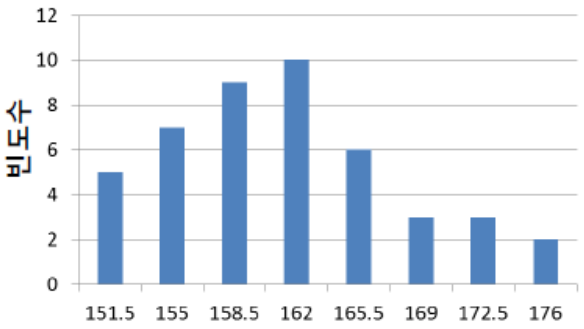

여대생 신장의 히스토그램

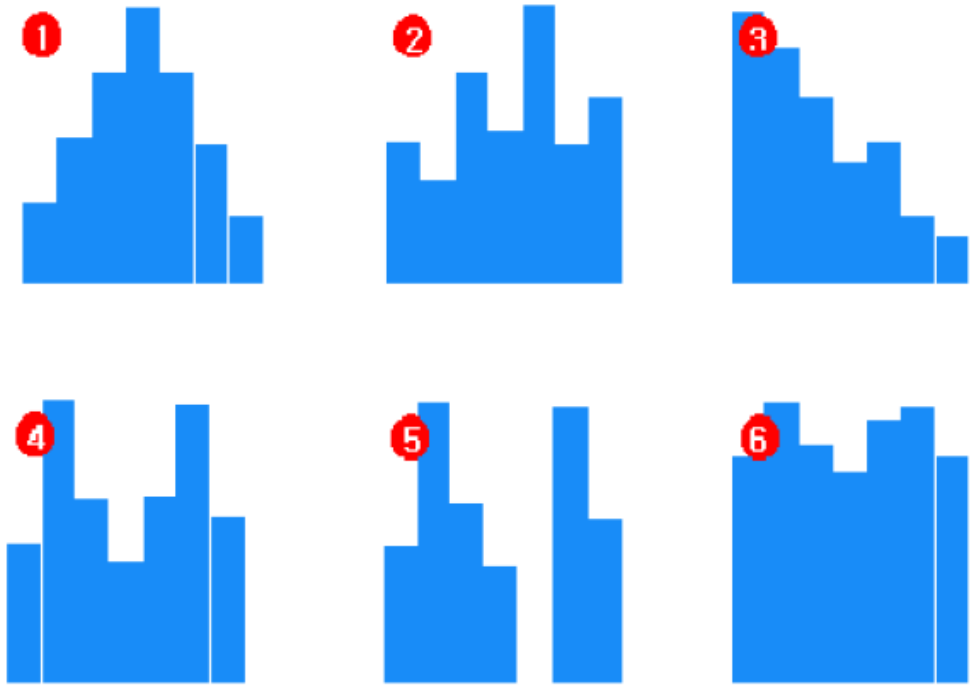

Source: http://www.allfortest.co.kr/customer.htm

(1) 일반형: 가장 흔하게 나타나는 분포로 도수가 중심 부근에 가장 많이 분포 되어있어 중심에서 멀어질수록 조금씩 작아진다. 거의 좌우 대칭이다.
(2) 이빠진형: 구간을 하나씩 걸러 도수가 작아진 분포의 모양이다. 이가 빠진 모양이 되고 있다. 이런 경우 구간 폭을 눈금의 정수 배로 한다든가, 측정자 읽는 법이 제대로 되었는가의 검토가 필요하다.
(3) 절벽형(왼쪽, 오른쪽): 평균값이 분포의 중심에서 극단적으로 한쪽에 치우쳐 있다. 이런 경우 측정속임수, 측정오차, 검사미스 등을 체크한다.
(4) 쌍봉우리형: 중심부근의 도수가 작아 산의 정상이 좌우로 나누어져 분포되어 있다. 이런 경우는 평균값이 다른 2개의 분포가 섞여 있을 경우에 나타나는데 층별한 히스토그램을 작성해보면 그 차이를 알 수 있다.
(5) 낙도형: 히스토그램의 왼쪽 끝이나 오른쪽 끝에 외딴 데이터가 나타난다. 이런 경우 데이터의 이력을 알아 보고 공정에 이상이 없는지, 다른 공정의 데이터가 들어와 있지 않은지 등을 조사한다.
(6) 고원형: 각 구간에 포함되어 있는 도수가 별 차이 없는 고원상태가 되고 있다. 이런 경우 층별한 히스토그램을 만들어 비교 검토한다.

Descriptive Illustrations: Box plot (1/2)

- **상자 그림 (Box plot)**
  - Data의 분포에 대한 정보를 사분위수를 중심으로 나타내 주는 그림

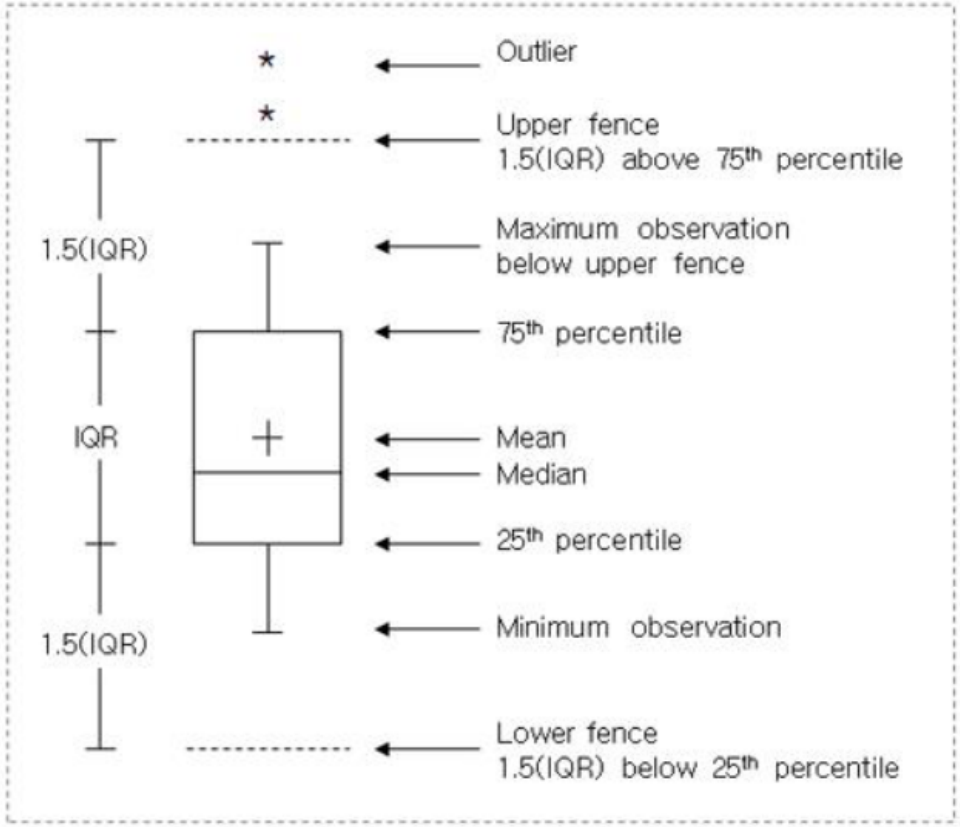

※ IQR : Inter Quantile Range

Histogram & Box Plot(1/2)

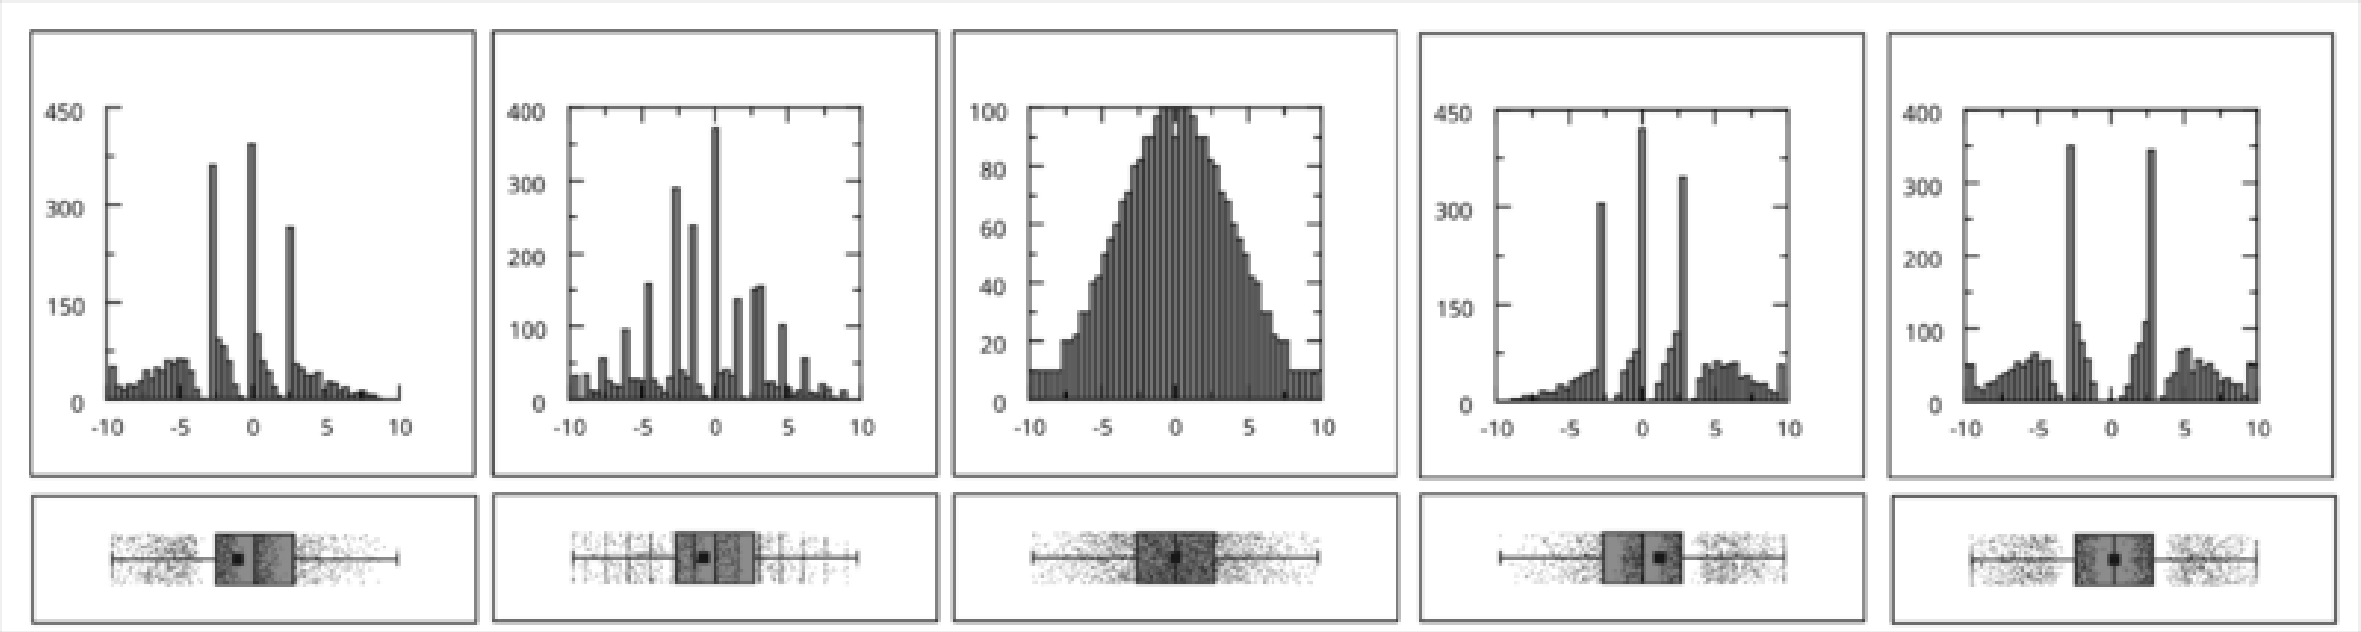

Histogram & Box Plot(2/2)

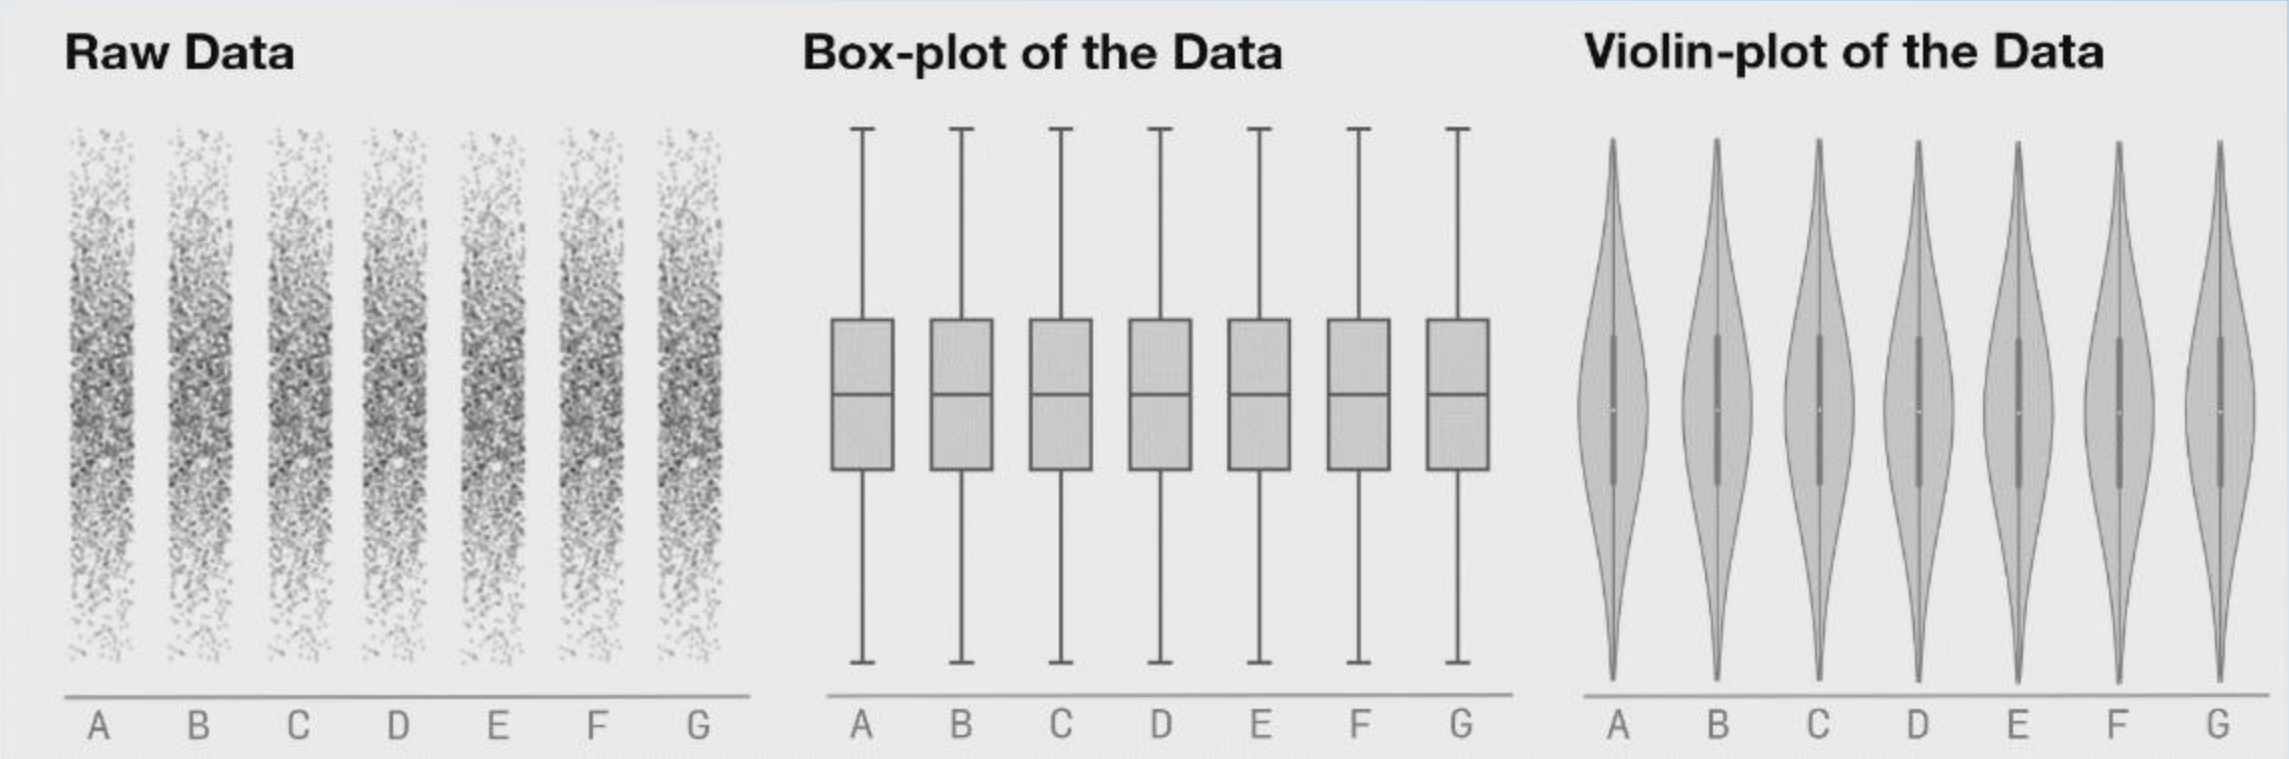

https://www.research.autodesk.com/publications/same-stats-different-graphs/

막대그래프 vs. 히스토그램

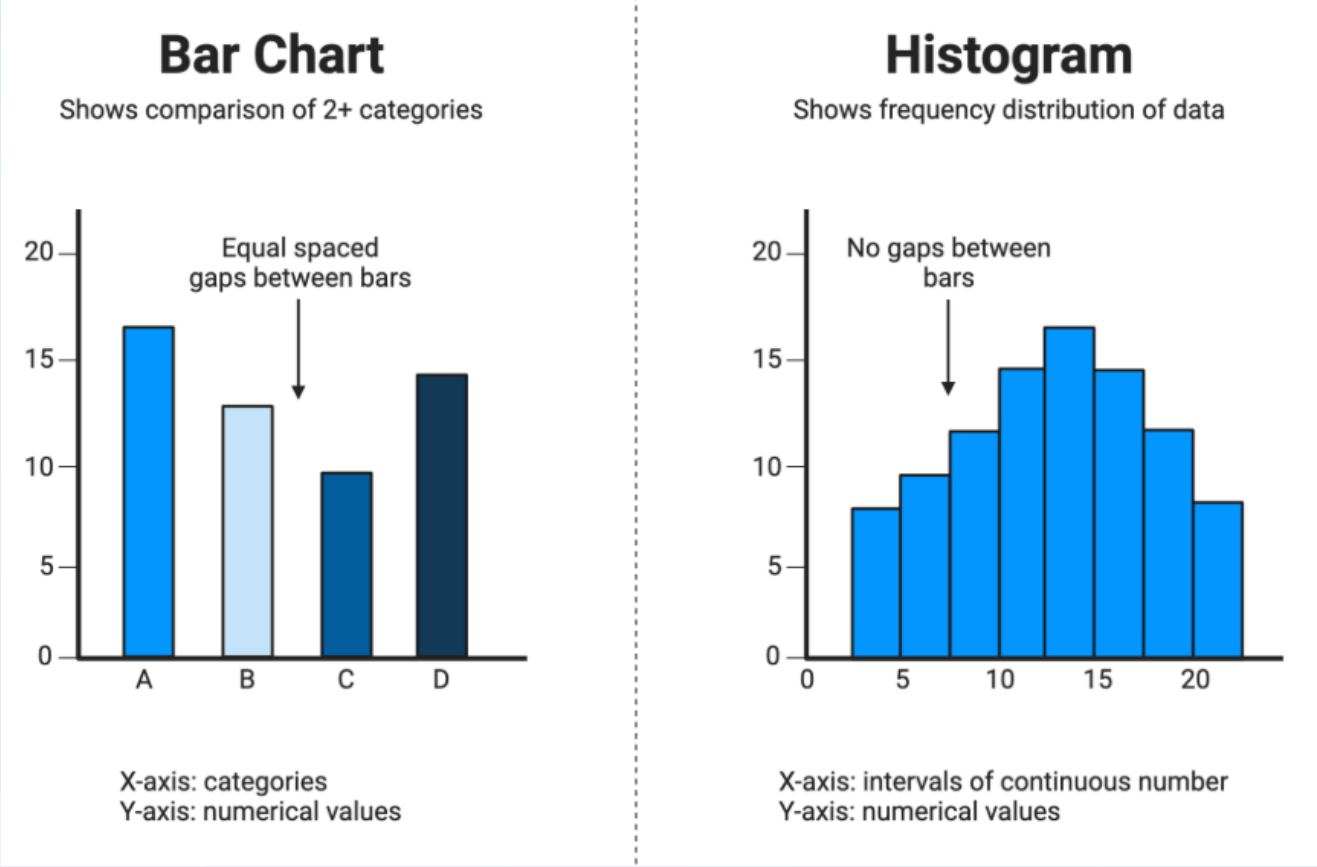

구분	막대그래프	히스토그램
데이터 유형	범주적(종교, 직업 등)	연속적(몸무게, 키,나아 등)
막대 순서	임의적으로 변경 가능	변경 불가능
막대 간격	일정한 간격 유지	간격 없이 표현
용도	범주의 비교, 순위 표시 등	데이터 분포 표현

문제 풀이

❖ sns.load_dataset("diamonds")의 데이터를 바탕으로 막대그래프(bar chart)와 도수분포도(Histogram)을 시각화하고 설명하라(범주형과 수치형데이터의 시각화 방법에 대해 토론하라)

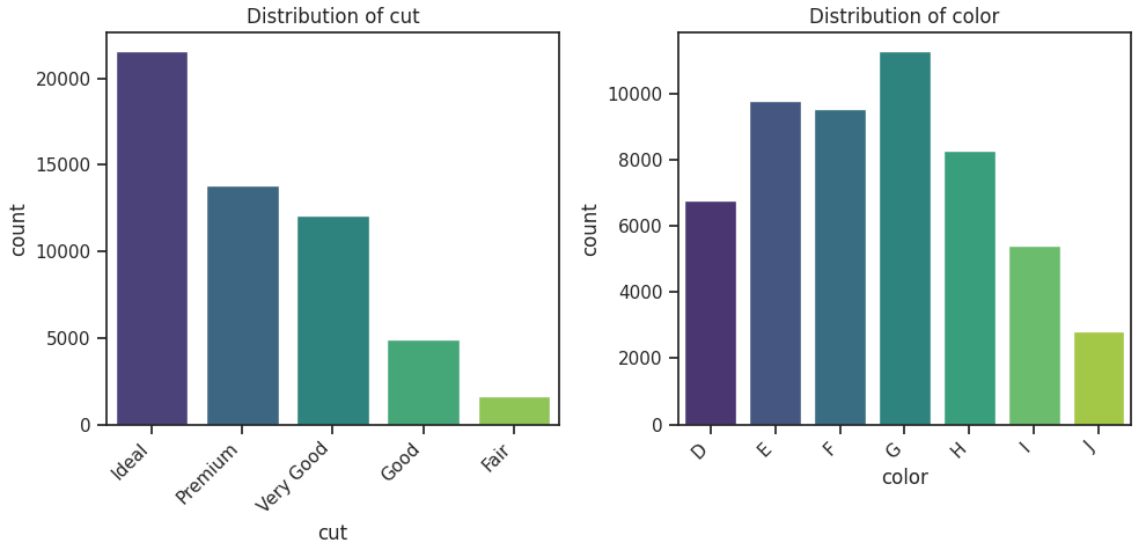

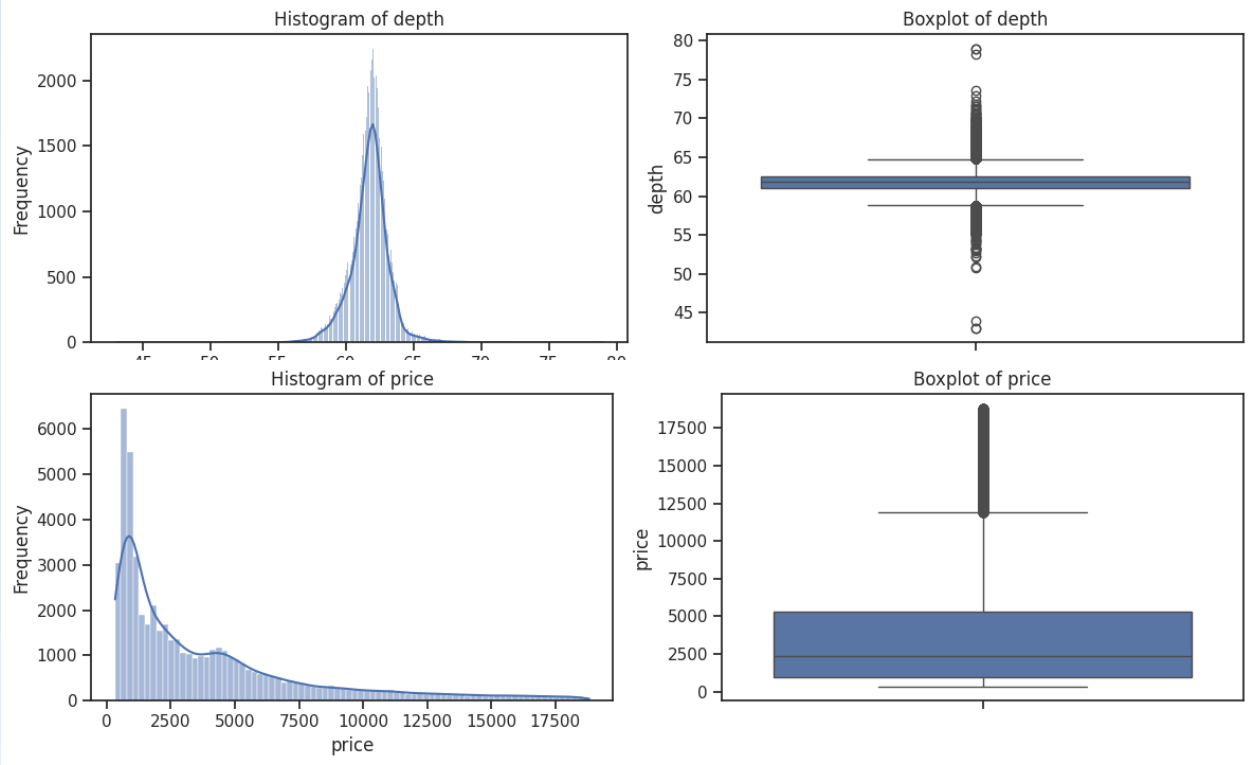

문제 풀이

- 아래 데이터소스에서 키, 몸무게, 수입의 값을 표준화하여 시각화하라
  - https://scikit-learn.org/stable/modules/preprocessing.html
  - 표준화(standardization): 변수의 관측치에서 평균을 차감한 값을 표준편차(분산의 제곱루트)으로 나는 값
- 표준화(standardization)를 하는 이유? 모든 변수의 값이 동일해지는 것 아닌가? 왜 이래야 하는지 설명하라(위키독스)

https://github.com/ancestor9/data/blob/main/human_data.csv

1	Person	height	weight	foot size
2	female	5.71	115.83	6.9
3	female	5.26	103.99	6.06
4	female	5.46	139.57	6.91
5	female	5.59	130.28	7.01
6	male	6.14	179.61	11.83
7	female	5.52	122.23	6.26
8	female	5.28	117.93	7.02

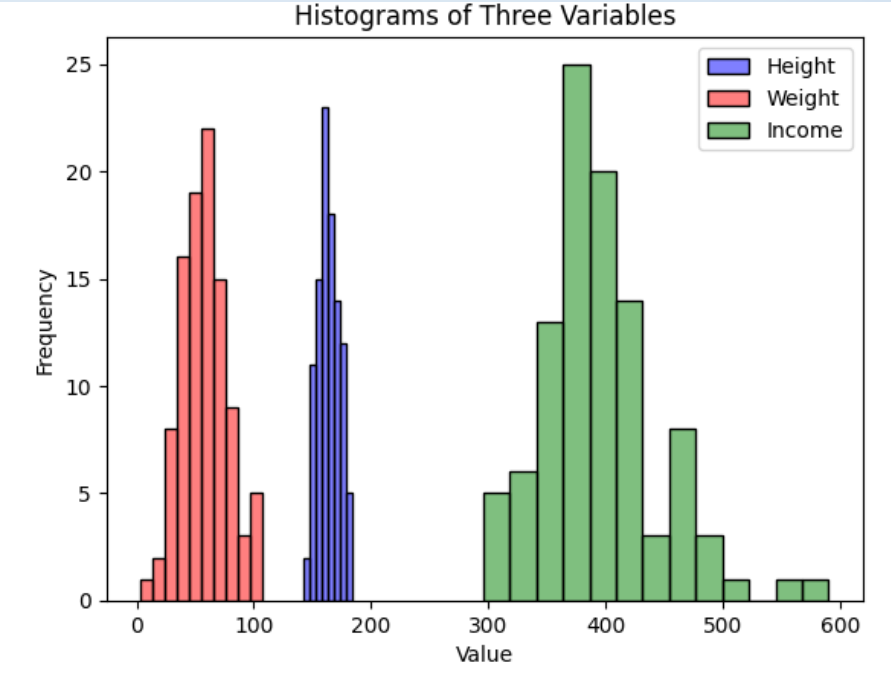

$$Z = \frac{X - \mu}{\sigma}$$

문제 풀이

- 수치형 변수 값의 서로 크기가 다른 경우 scaling하는 방법과 그 이유를 토론하라(Data scaling)
  - from sklearn.datasets import fetch_california_housing 의 데이터의 변수 중 "MedInc", "AveOccup" 에 대한 joinplot을 시각화하라
  - https://scikit-learn.org/stable/auto_examples/preprocessing/plot_all_scaling.html 자료원을 이해하고 평균과 분산이 각각 0과 1인 형태로 표준화한 후 시각화 코드를 만들어라

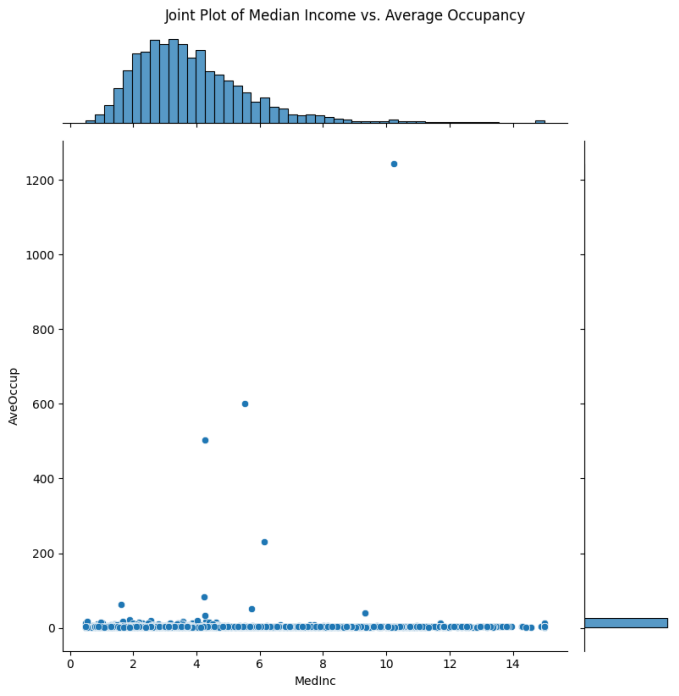

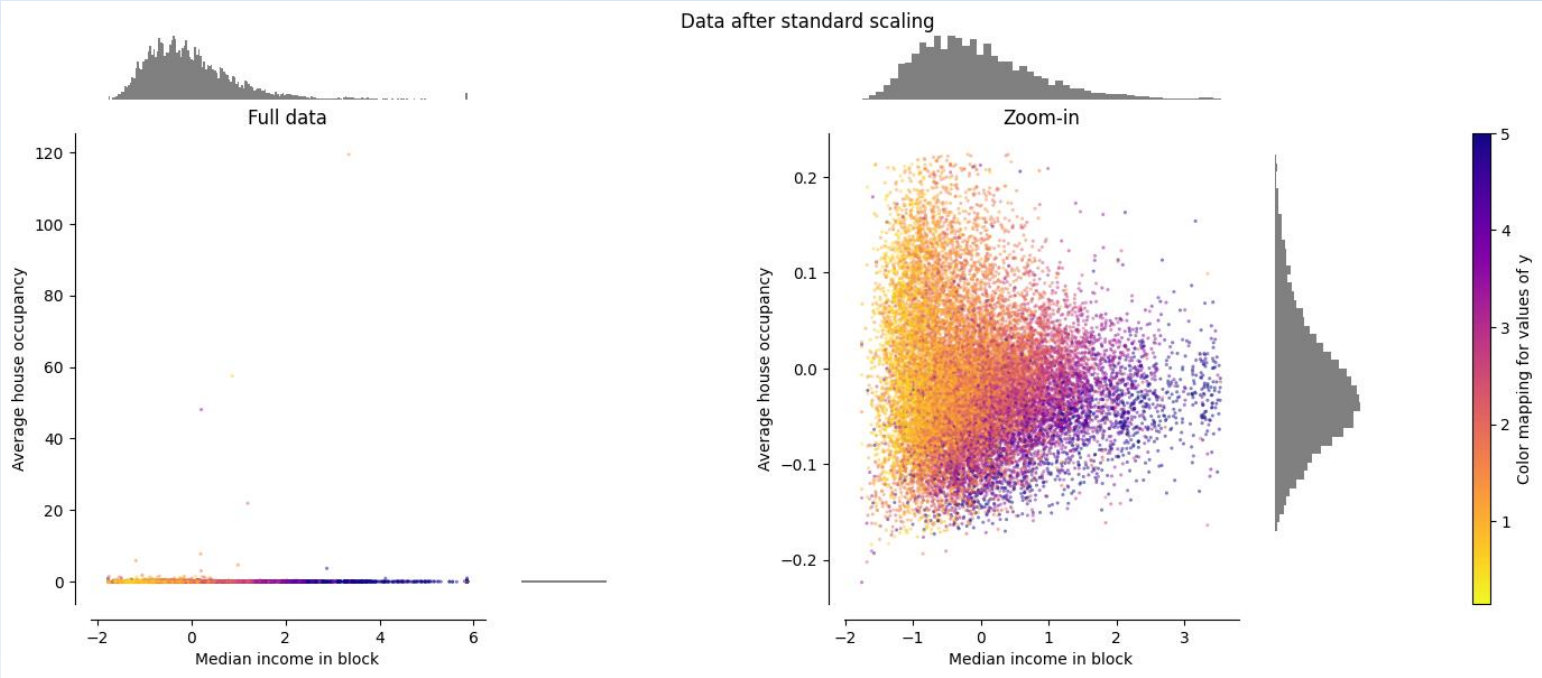

Descriptive Statistics: 왜도

- **왜도 (Skewness)**
  - 자료의 분포에 대한 비대칭의 정도
  - 비대칭이 없는 경우 왜도 = 0

$$skewness = \frac{1}{n-1}\sum_{i=1}^{n}\left(\frac{X_i - \bar{X}}{s}\right)^3$$

평균,
중간값의
위치?

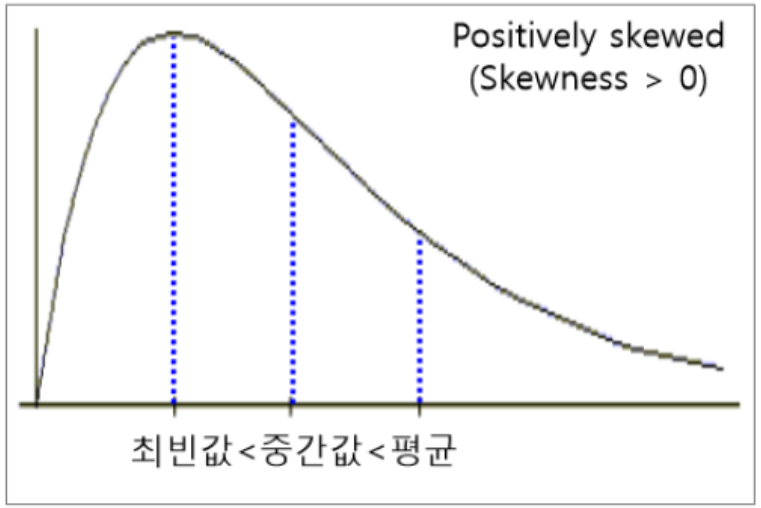

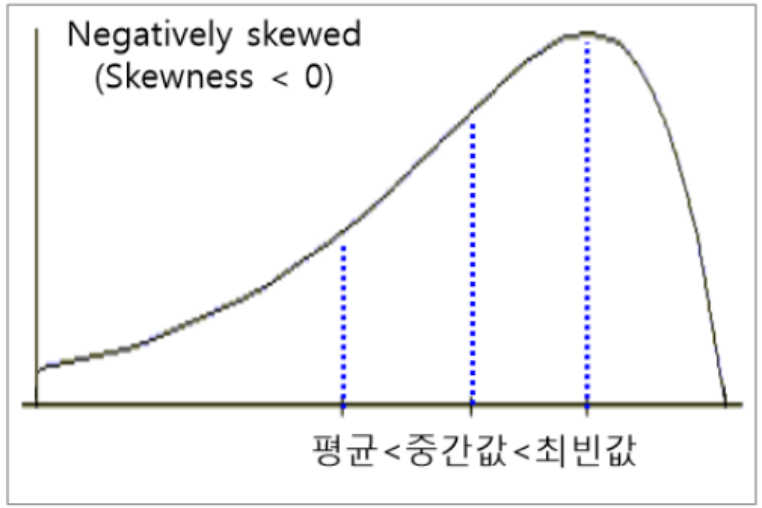

- Ex) 500, 489, 495, 493, 505, 248 → *skewness* = -2.5

Descriptive Statistics: 첨도

- **첨도 (Kurtosis)**
  - Data 분포의 뾰족한 정도
  - 표준정규분포의 경우 첨도 = 0

$$Kurtosis = \frac{1}{n-1}\sum_{i=1}^{n}\left(\frac{X_i - \bar{X}}{s}\right)^4 - 3$$

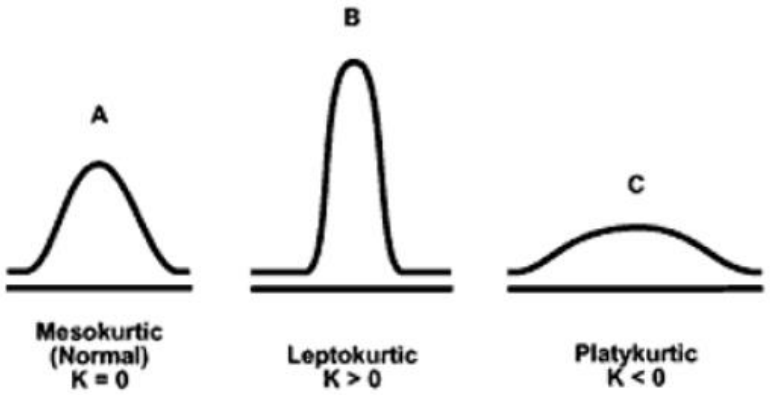

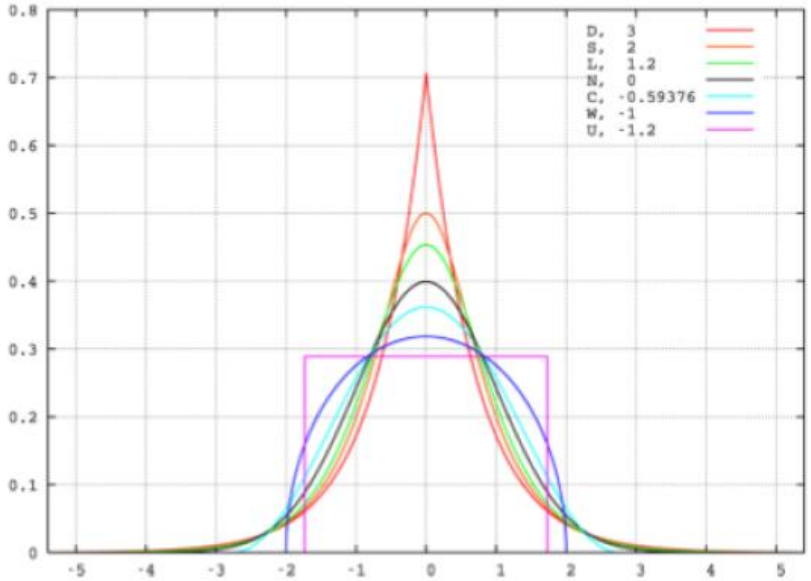

- Ex) 500, 489, 495, 493, 505, 248 → *Kurtosis* = 5.93

문제 풀이

❖ 변수의 값이 크게 차이가 나는 경우 혹은 왜곡된 경우 전처리하는 방법(3가지)을 통해 histogram 만들기

① 로그 변환 (Log Transformation)

② 루트 변환 (Square Root Transformation)

③ 박스-콕스 변환 (Box-Cox Transformation)

sns.load_dataset("diamonds")의 price 변수 값의 skew()를 구하고 위의 2가지 방법으로 변환하고 히스토그램을 시각화하라

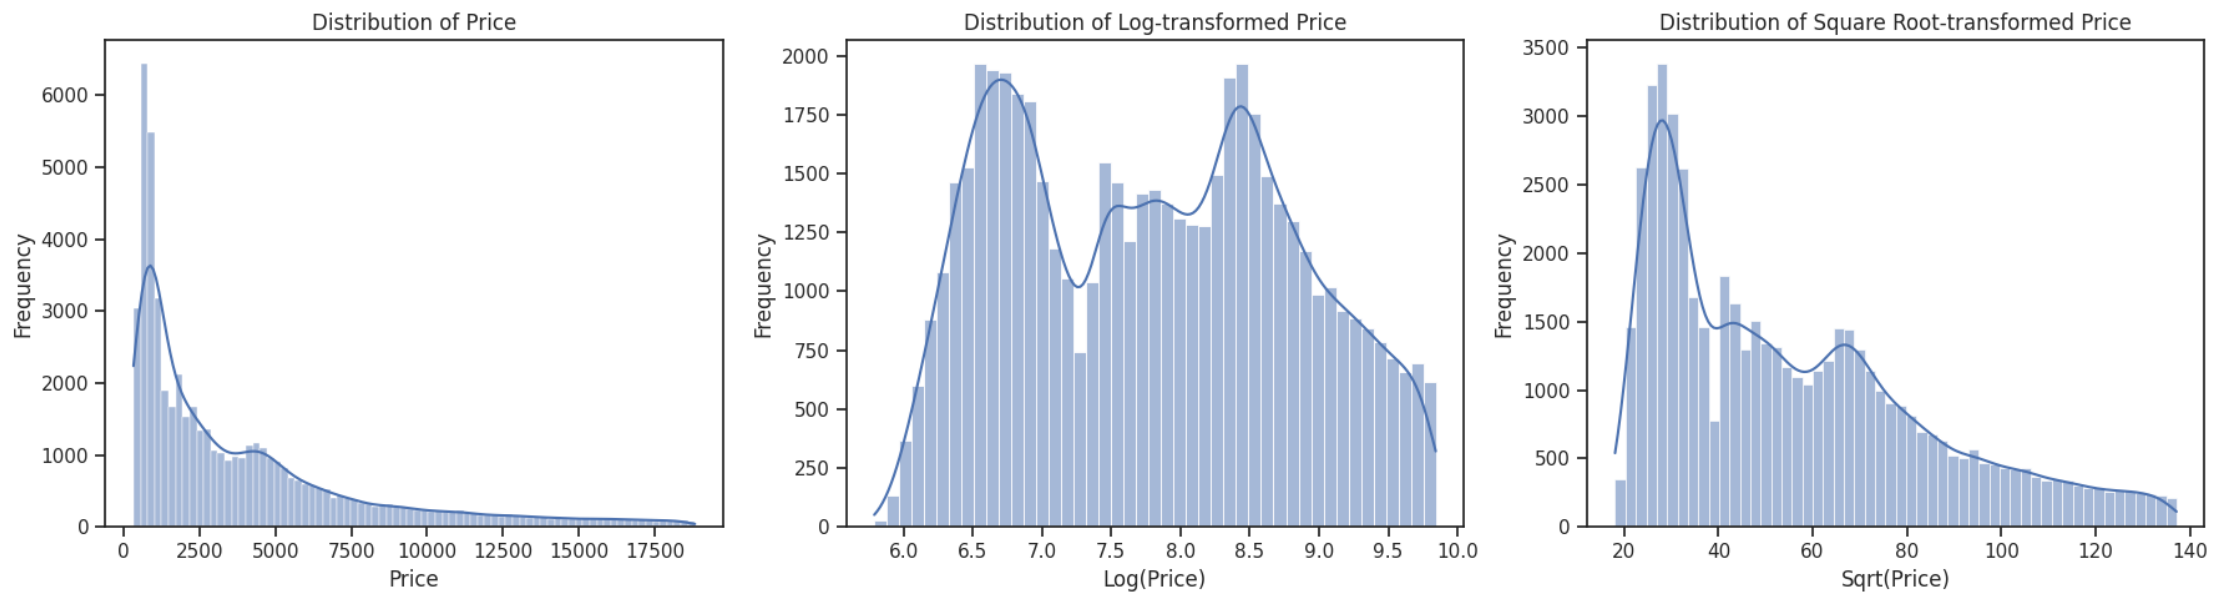

skewness = 1.62

skewness = 0.12

skewness = 0.84

문제 풀이

❖ seaborn의 histogram_stacked 의 log변환에 대해 설명하고 분산의 산술식과 비교하라

price 원자료

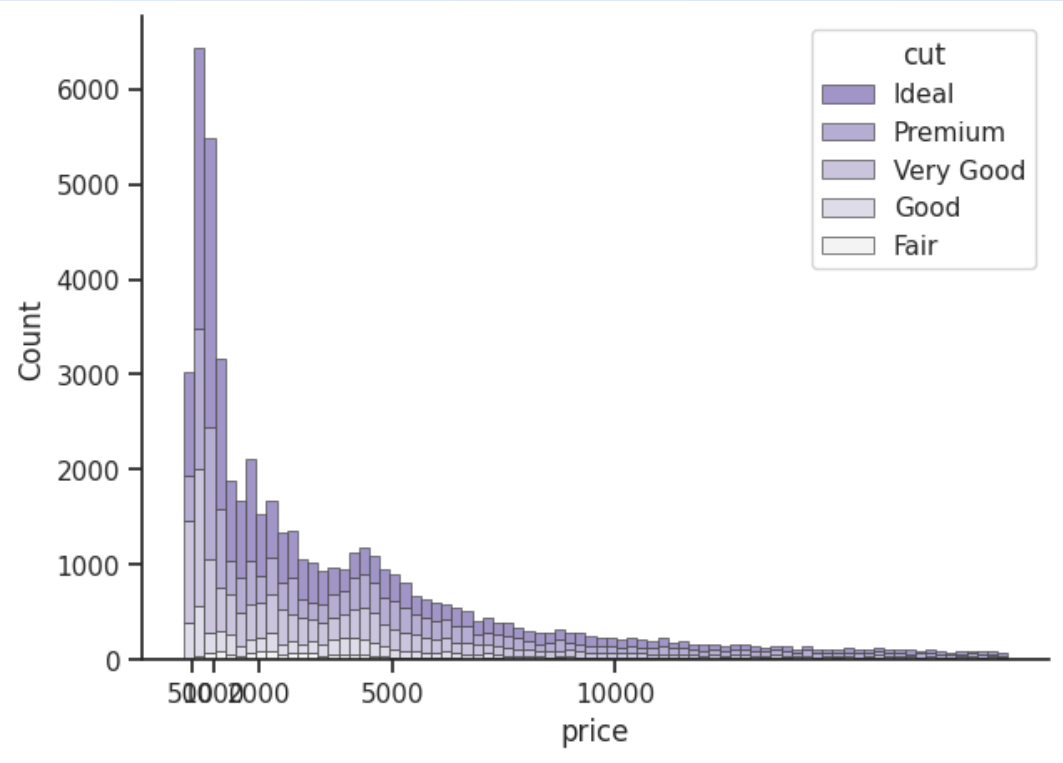

price 로그변환 자료

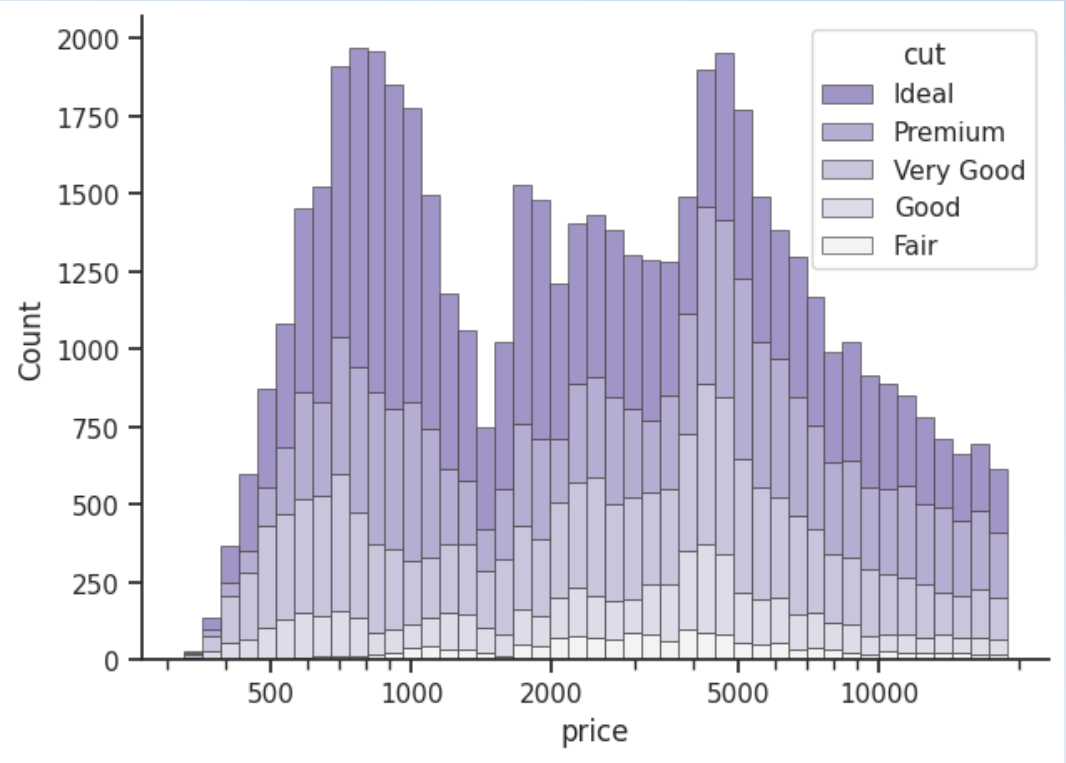

상관 분석

Multivariate Analysis(다변량 분석)

산점도

- **산점도(scatter plot)**
  - (x_1,y_1), (x_2,y_2), …, (x_n, y_n)평면좌표에 표시한 도표
  - 시각적으로 두 변수의 관계를 쉽게 알 수 있게 해줌
  - 변수간 관계의 방향, 형태, 관계의 강도를 알 수 있음

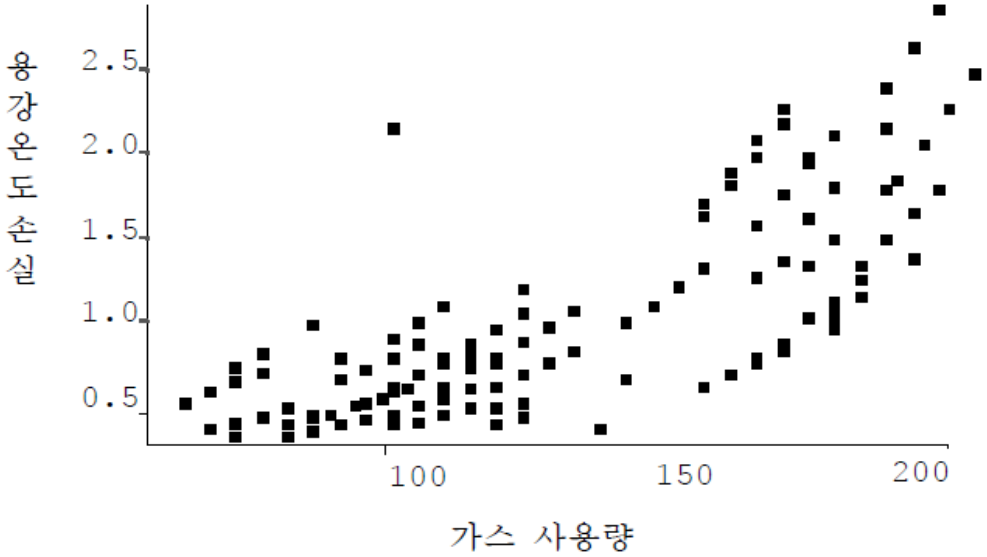

Scatter Plot(1/2)

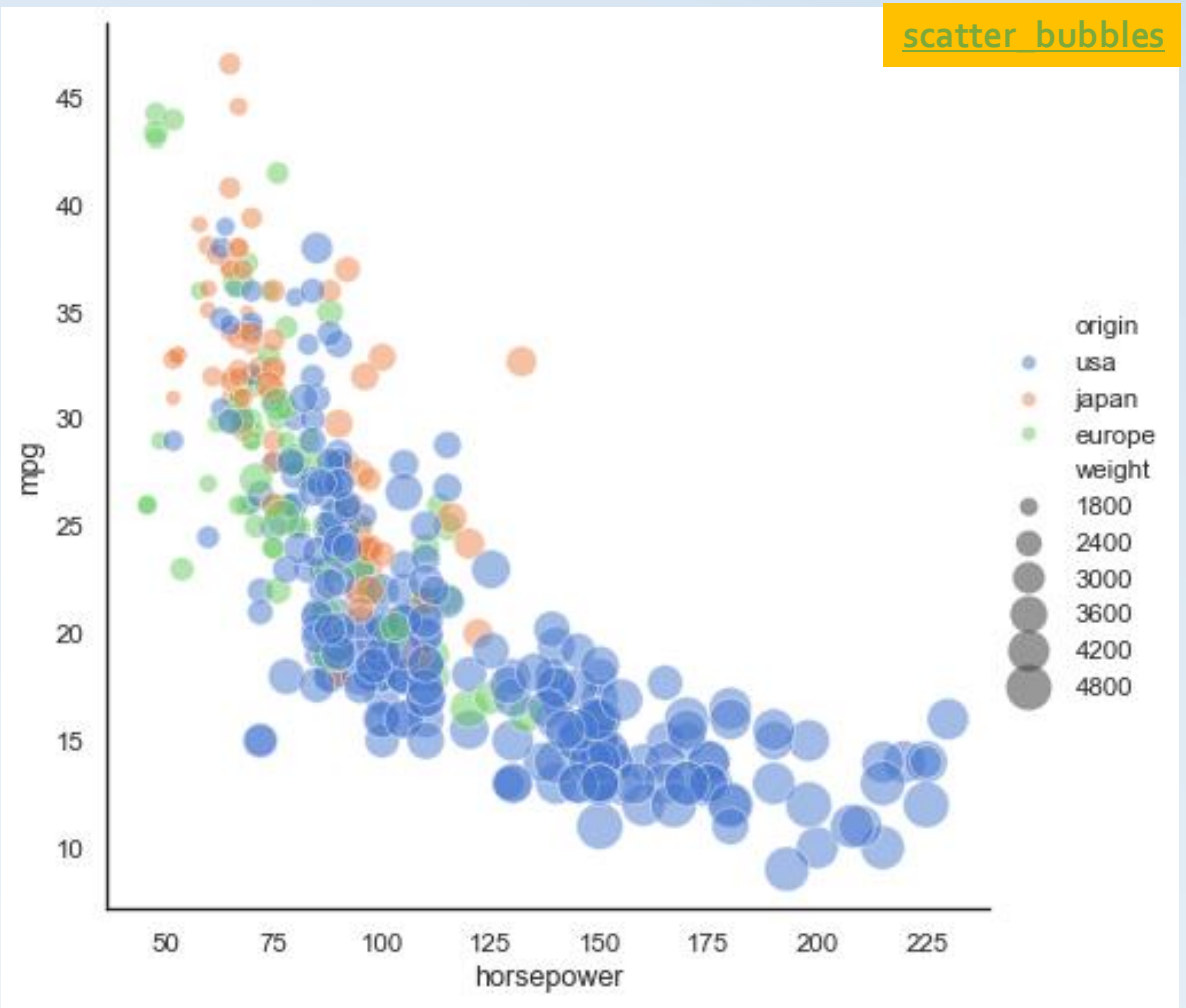


```
import seaborn as sns
sns.set_theme(style="white")

# Load the example mpg dataset
mpg = sns.load_dataset("mpg")

# Plot miles per gallon against horsepower with other semantics
sns.relplot(
            x="horsepower",
            y="mpg",
            hue="origin",
            size="weight",
            sizes=(40, 400),
            alpha=.5,
            palette="muted",
            height=6,
            data=mpg
            )
```

공분산과 표본공분산

- **공분산(Covariance)**
  - 두 확률변수 X와 Y의 선형적 상관관계를 측정할 수 있는 척도
  - X와 Y가 각각의 평균을 중심으로 하여 같은 방향으로 변화하는 정도를 나타냄
  - $\sigma_{xy}=Cov[X, Y] = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$
  - 공분산 값의 크기가 단위 등에 따라 달라짐

- **표본 공분산 (Sample Covariance)**
  - σ_{xy} 의 추정량으로 S_{xy} 로 표현

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y}) = \frac{1}{n-1}(\sum_{i=1}^{n} X_i Y_i - n\bar{X}\bar{Y})$$

상관계수와 표본상관계수 (1/3)

- **상관계수**
  - 공분산을 단위와 무관하게 표준화시킴
  - -1 에서 1까지의 값을 가짐

$$\rho_{XY} = \frac{Cov[X,Y]}{\sqrt{Var[X]}\sqrt{Var[Y]}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

- **표본상관계수**
  - 상관계수의 추정량으로 r_{xy} 로 표현

$$r_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}}$$

상관계수와 표본상관계수 (2/3)

- 표본상관계수에 따른 산점도

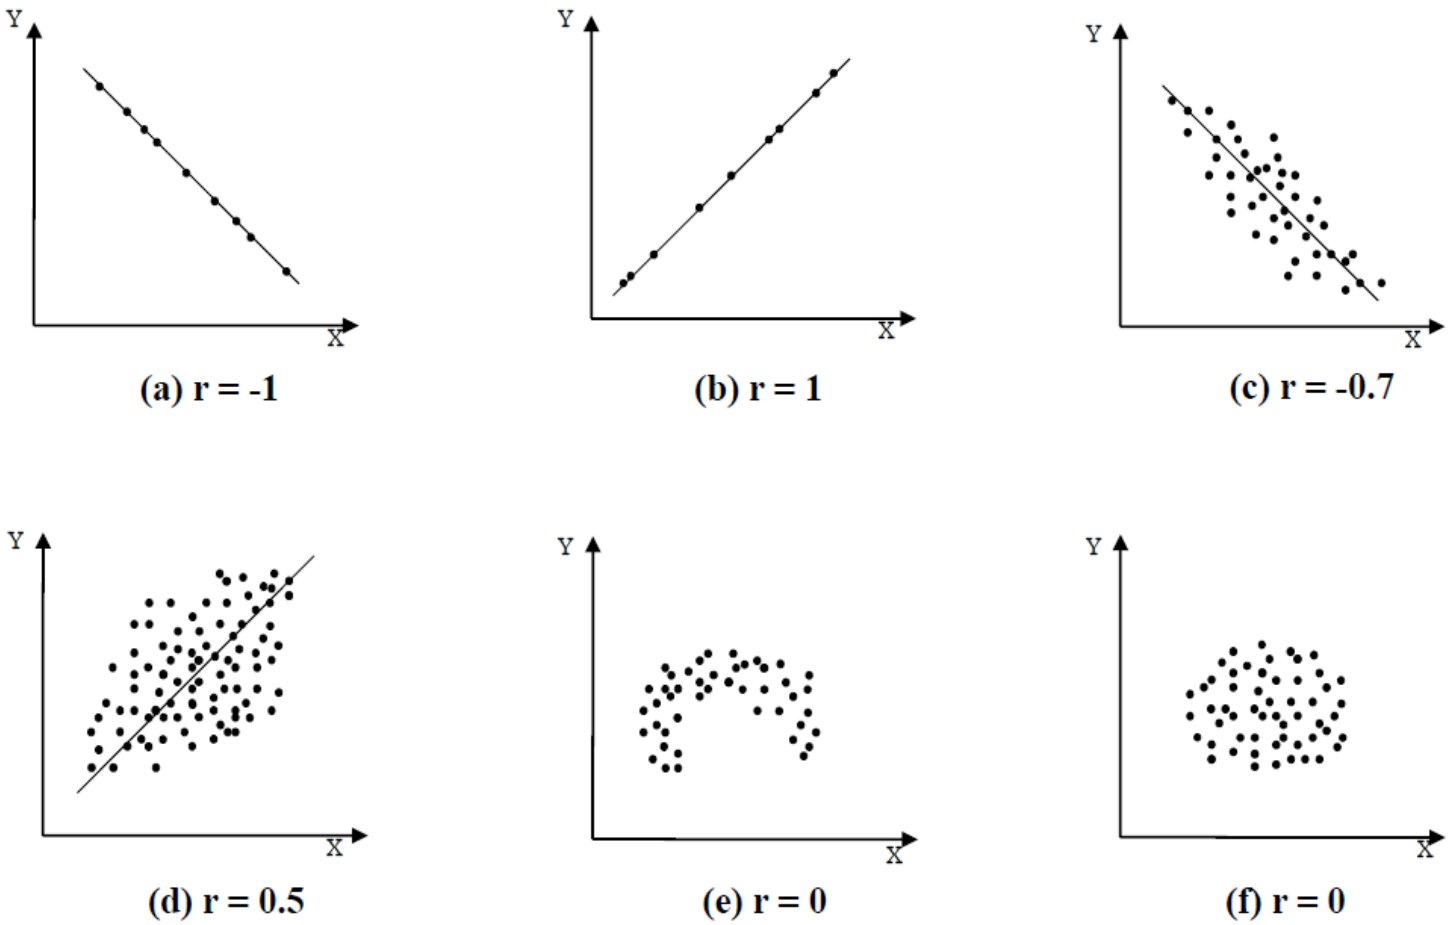

same-stats-different-graphs

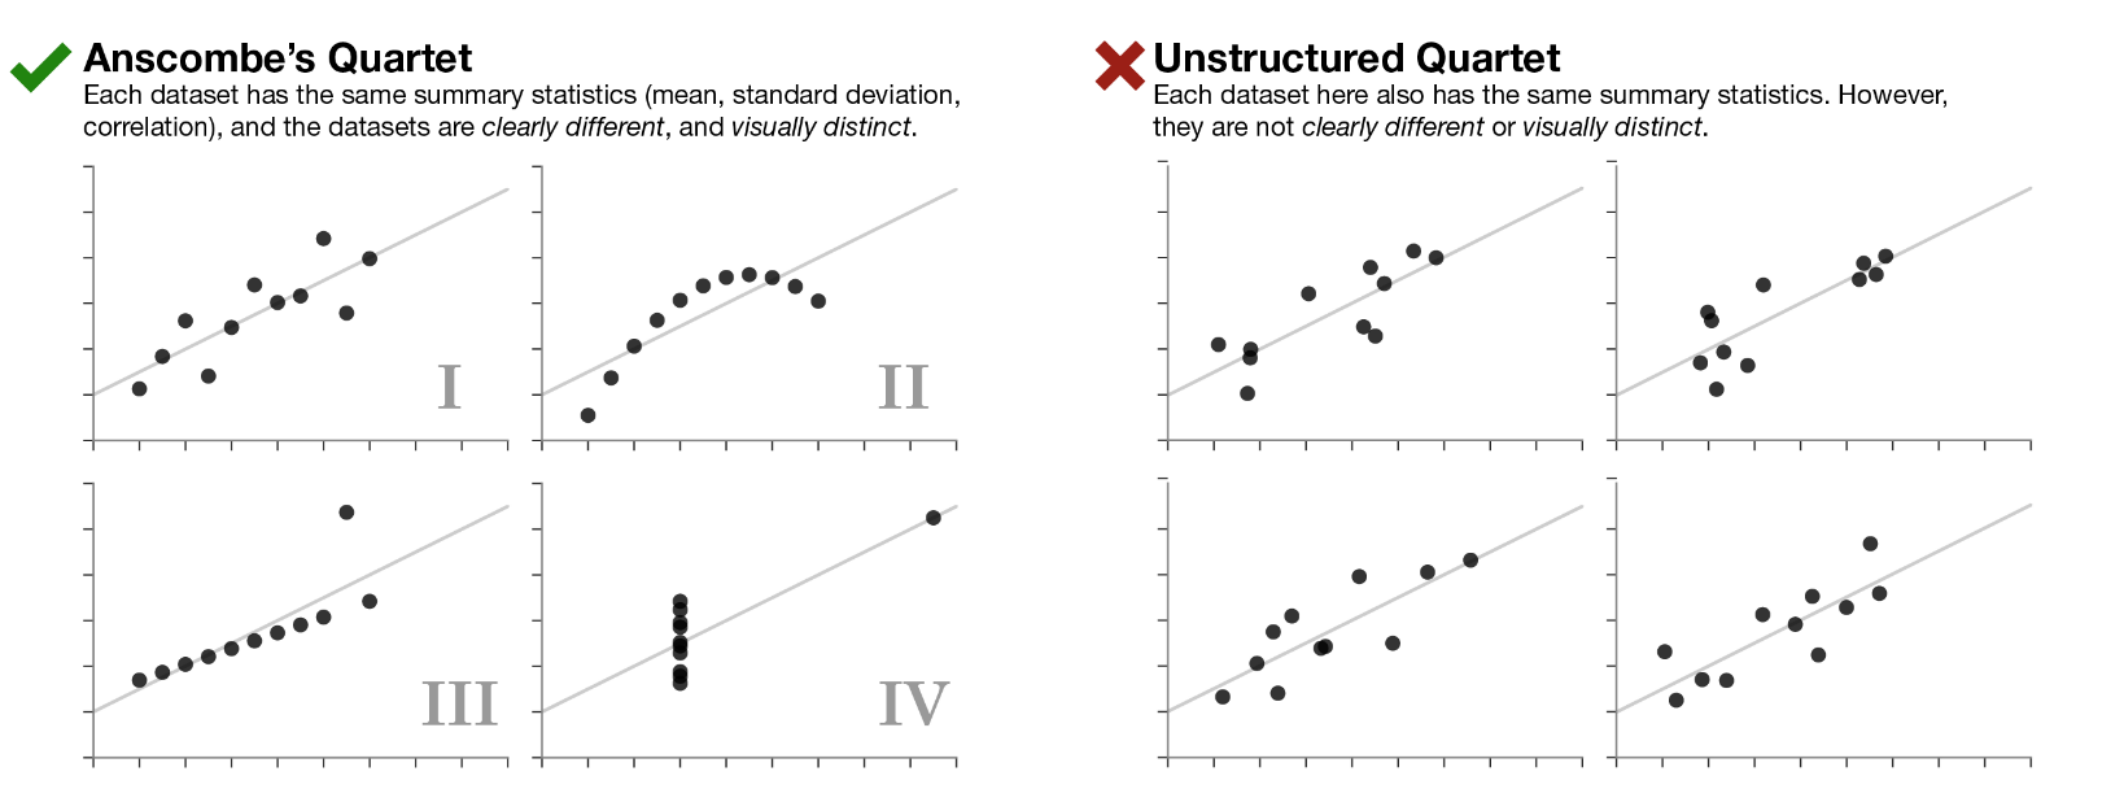

문제 풀이

❖ colab의 ancombe.json 파일을 사용하여 각 그룹별로 X,Y 변수의 평균, 분산, 표준편차, 상관계수를 구하라

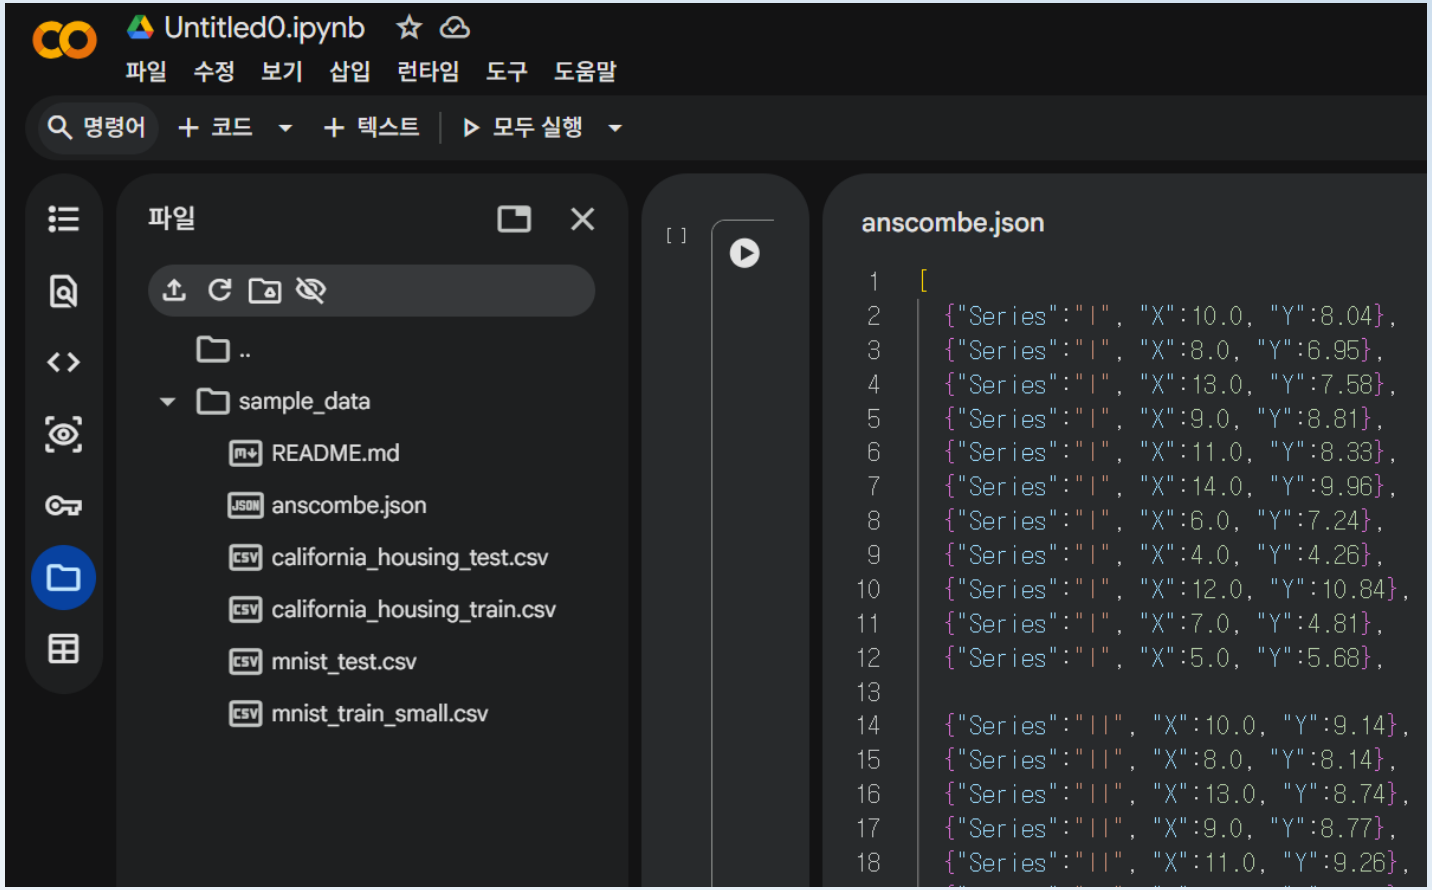

문제 풀이(시각화, Data Visulalization)

❖ 통계량(Statistic)을 이해하지 못하면 시각화는 하지 마라

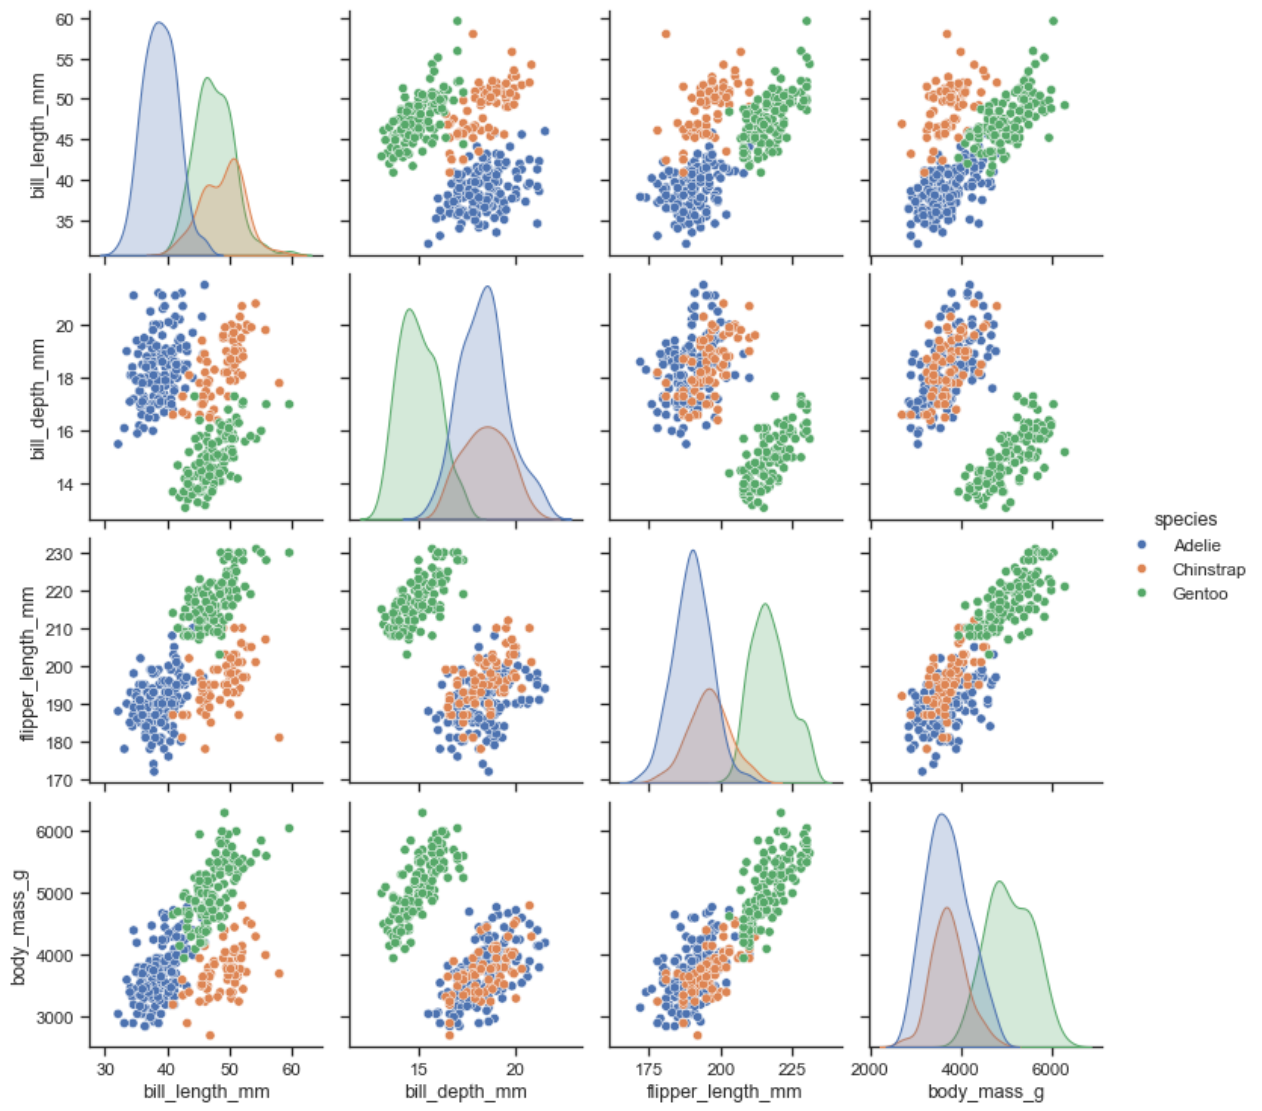

❖ scatterplot_matrix

❖ 3가지 팽귄 종류를 분류하기에 가장 적합한 변수는?

문제 풀이(시각화, Data Visulalization)

❖ seaborn gallery의 시각화 예제 중에서 아래 그림을 평균, 분산, 왜도, 분포 등의 관점으로 설명하라

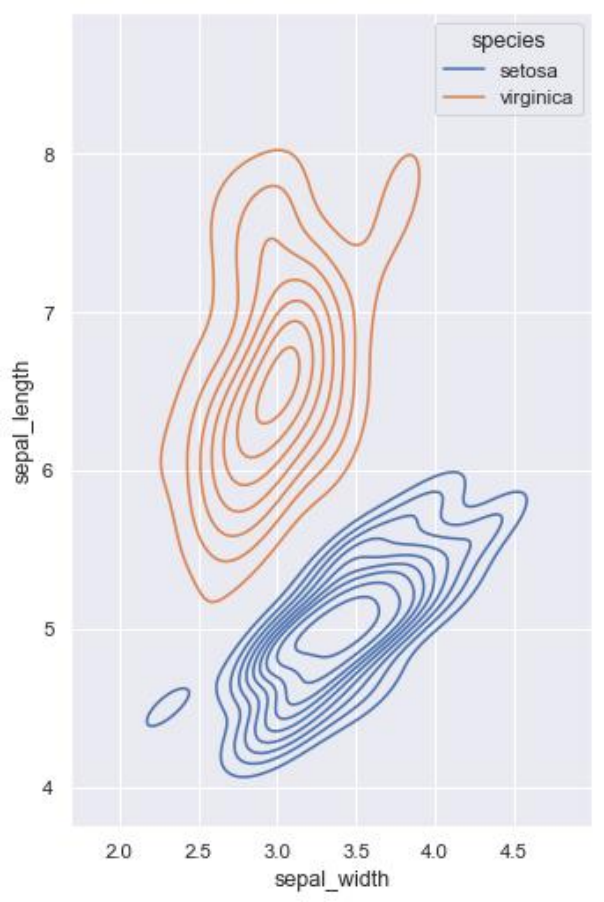

multiple_bivariate_kde

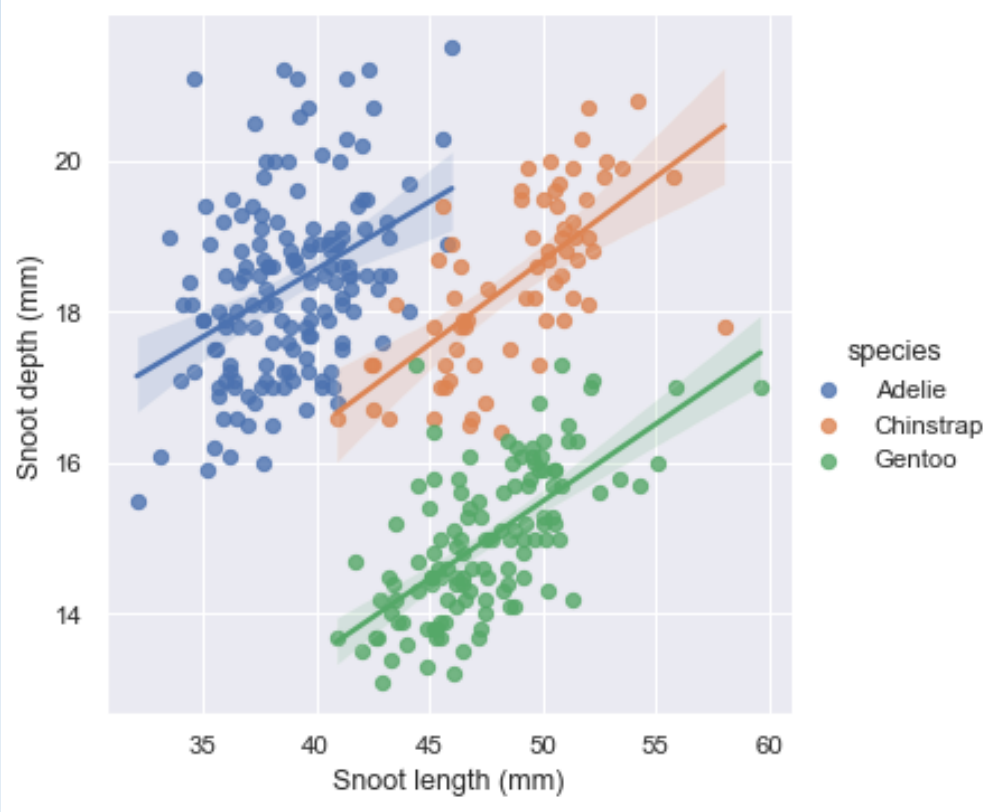

multiple_regression

문제 풀이(시각화, Data Visulalization)

https://seaborn.pydata.org/examples/joint_kde.html

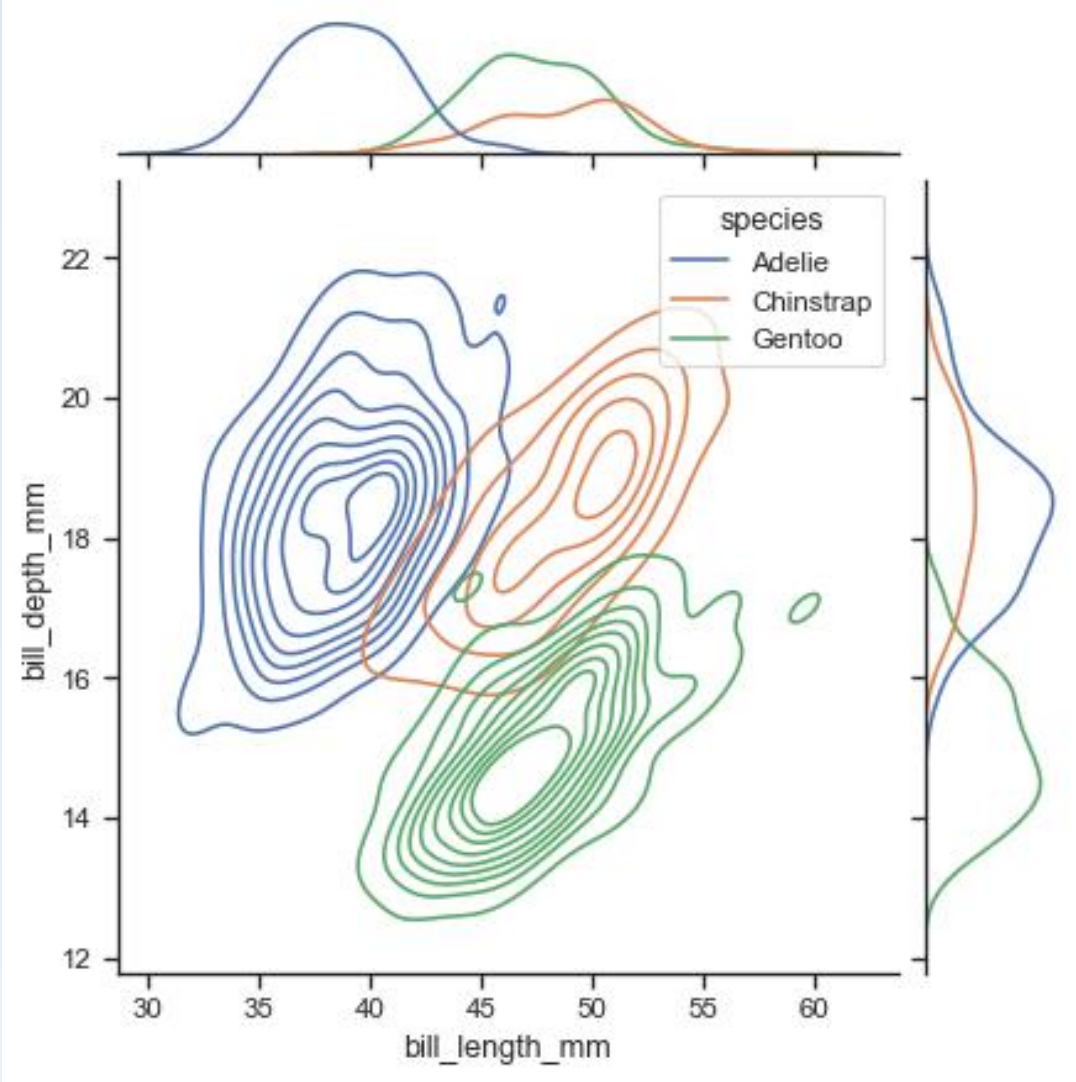

- 변수명 "species"의 범주형 값을 기준으로
  - x, y축의 각각 변수의 평균과 분산을 구하라
  - x, y 의 변수간의 공분산을 구하라
  - 분산이나 공분산이 커지면 모양새는 어떻게 변하나?
- 낙도(remote island)는 무엇인가?
- 팽권 3 종(species)를 분류하기에 가장 좋은 변수는 x, y 중에서 무엇인지 결정하라
  - 분류를 결정하는 변수의 어떤 특정 값이 3 종(species)을 분류(classification)하는데 최적인가?

문제 풀이(시각화, Data Visulalization)

❖ X 값이 1, 2, 3, 4, 5인 각각의 데이터는 Cluster 1과 2중에 어디에 속할까? 아래 시각화 그림에 대해 토론하라

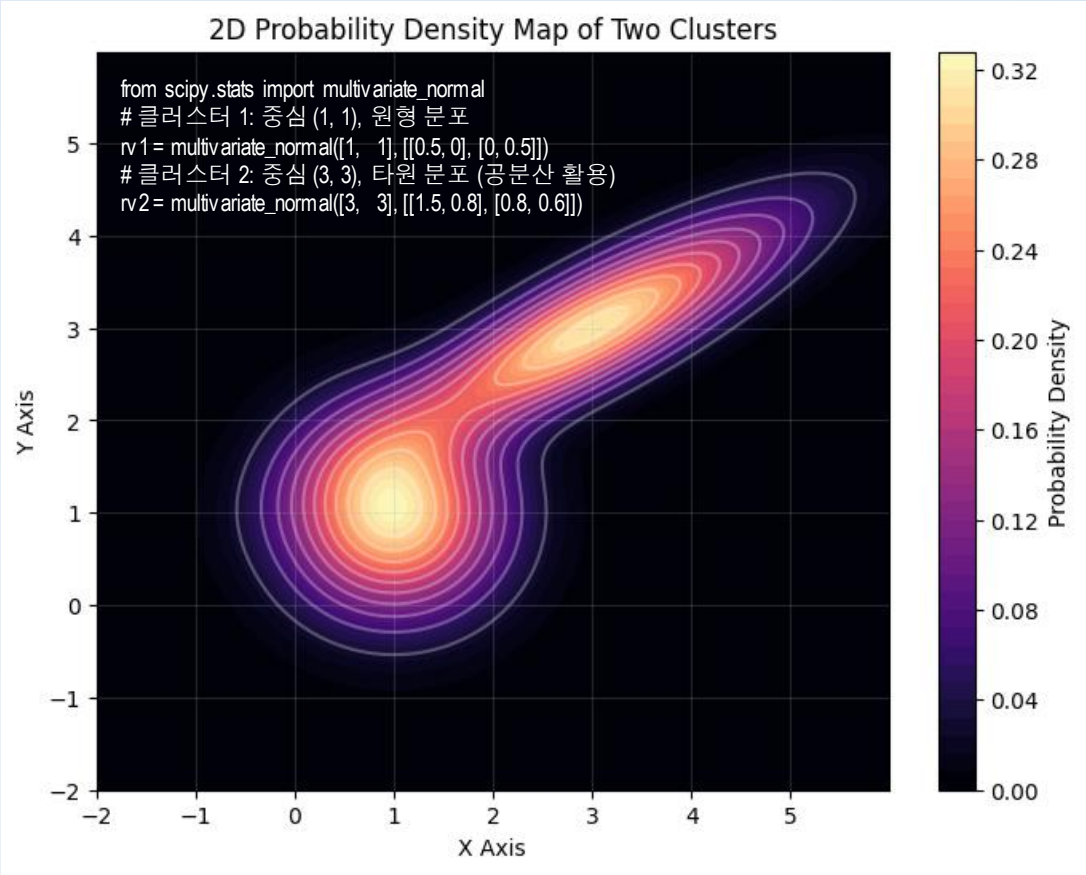

문제 풀이(시각화, Data Visulalization)

- ❖ X 값이 1,2, 3, 4, 5인 각각의 데이터는 Cluster 1과 2중에 어디에 속할까? 아래 시각화 그림에 대해 토론하라
- ❖ X 값이 2일 경우 어디에 속하는지 수자로, 확률로 제시할 수 있을까?

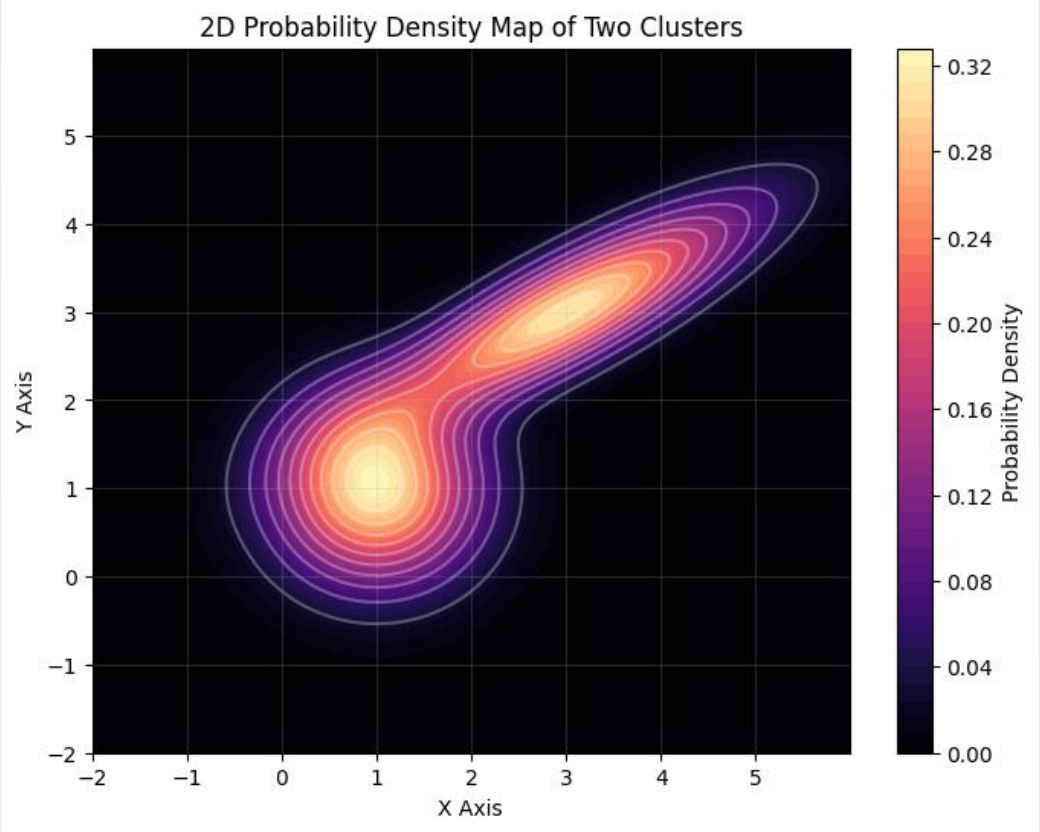

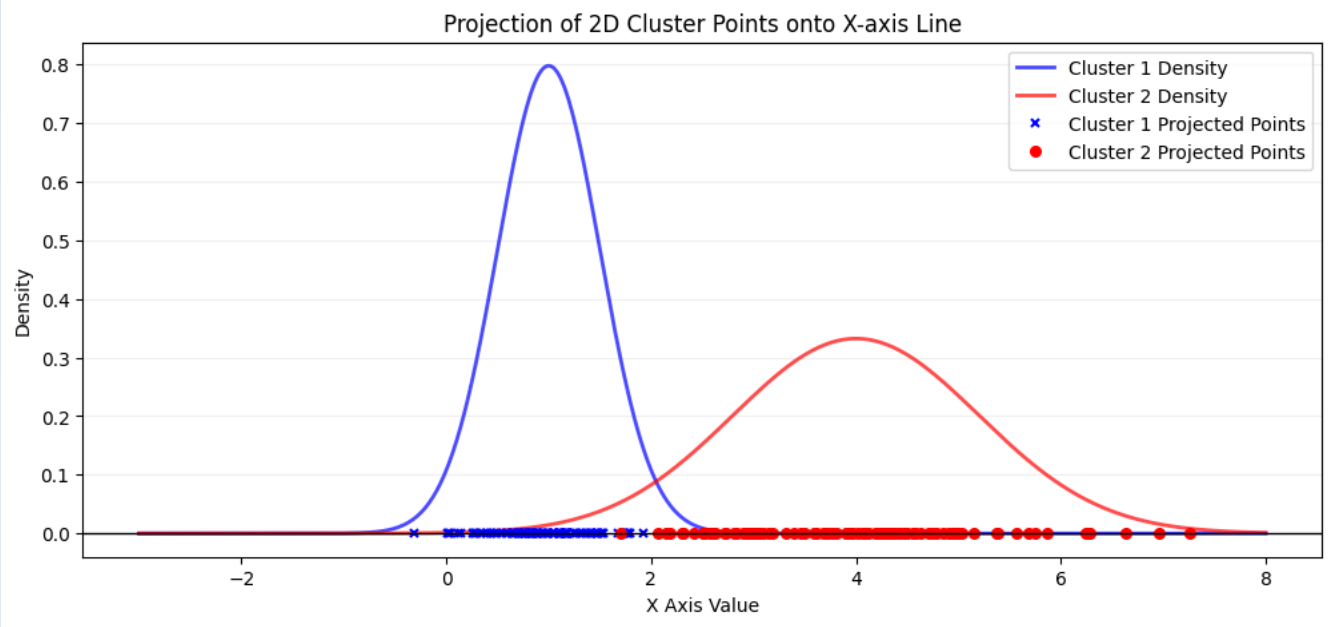

✓ 러그 플롯(Rug Plot) : 2차원 공간(X, Y)에 흩어져 있는 점들을 Y축 값을 무시하고 X축 바닥으로 뚝 떨어뜨려(투영시켜), 실제 데이터가 어느 지점에 밀집해 있는지를 직선상의 눈금으로 표시

문제 풀이(시각화, Data Visulalization)

- ❖ 대표적인 주요 시각화 예제 (나폴레옹군대 , 나이팅게일, 콜레라 등)를 검색하여 설명하라
- ❖ informationisbeautiful를 참고하여 시각화 예제를 살펴보기

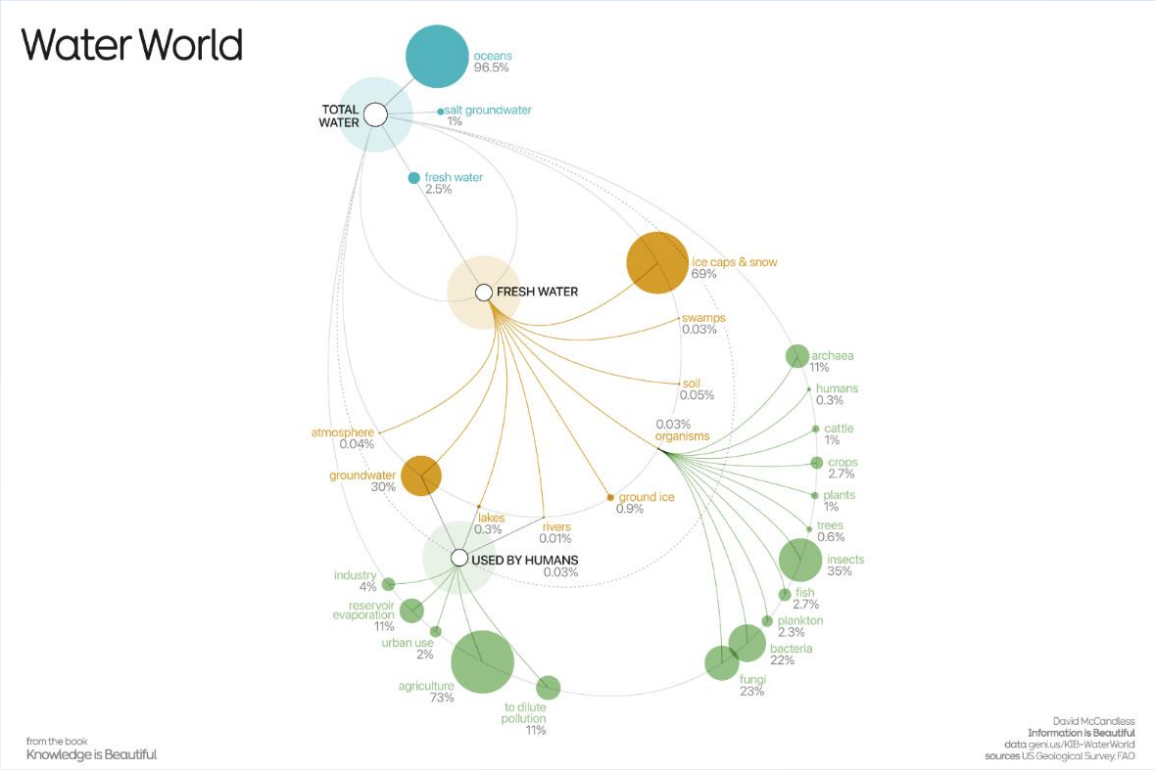

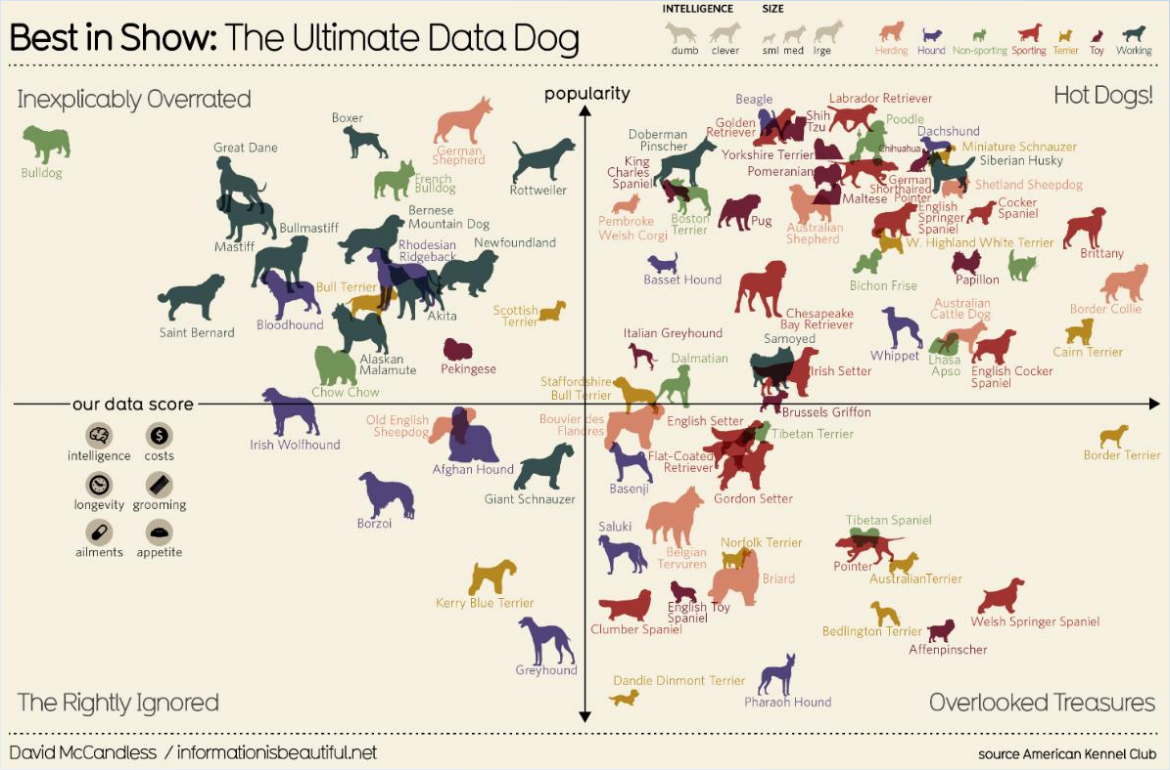

문제 풀이(Option)

❖ Kaggle의 alone-in-the-woods-using-theil-s-u-for-survival를 참고하여 아래 데이터를 바탕으로 target을 성별로 하고 다른 모든 변수를 입력변수(Input)로 하여 상관관계(실수, 범주 모두 포함)를 아래와 같이 구하고 결과를 토론하라

https://github.com/ancestor9/data/blob/main/customers.csv

기술 통계분석(Descriptive Statistics Analysis)

- ❖ 모집단으로부터 수집된 데이터를 잘 요약하여 모집단에 대하여 유용한 정보를 생산한다.
- ❖ 데이터를 그래프, 표 또는 대표값 등을 나타내는 숫자(통계량)나 시각화로 요약한다.

Summary

- **Sampling 방법**
  - 단순무작위추출법
  - 층화무작위추출법
  - 집락추출법

- **Descriptive statistics**
  - 대표값: 평균, 중앙값, 최빈값
  - 산포: 범위, 사분위범위, 분산, 표준편차
  - 왜도, 첨도

- **Descriptive illustration**
  - Histogram
  - Box plot

과제 제출

LE PENSEVR
DE RODIN OFFERT
PAR SOVSCRIPTION
PVBLIQVE AV PEVPLE
DE PARIS MCMVI

탐색적 데이터 분석(EDA, Exploratory Data Analysis) 보고서 작성 제출(1/3)

- OpenML 사이트(https://www.openml.org/)의 아래 데이터를 아래 4가지의 다양한 방법(모듈)으로 데이터셋으로 읽고 어떤 데이터인지 설명하라
  - openml
  - fetch_openml
  - StringIO
  - requests

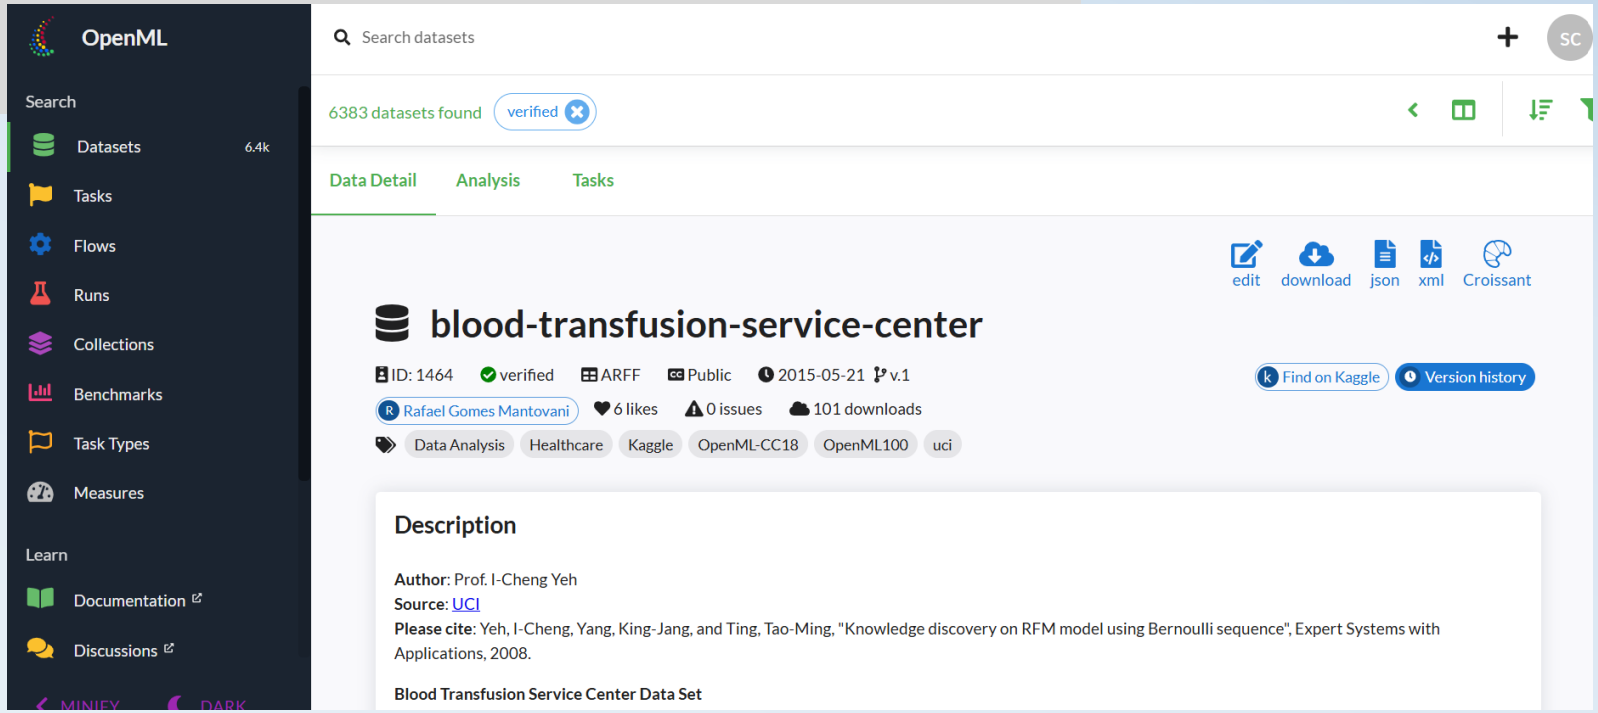

탐색적 데이터 분석(EDA, Exploratory Data Analysis) 보고서 작성 제출(2/3)

- 본격적인 모델링이나 가설 검정에 들어가기 전, 데이터를 다각도로 관찰하여 데이터의 특징을 이해하는 과정
  - 마치 요리를 하기 전 재료의 상태(신선도, 양, 종류)를 꼼꼼히 살피는 것
  - 생성형 AI Gemini canvas 기능을 사용하여 보고서를 작성하여 과제로 제출하라

- 통계 분석 항목 정리(각 변수별로)
  - 대표값
    - 평균, 중앙값, 최빈값
  - 산포
    - 범위 =
    - (Q1, Q2, Q3) =
    - 사분위범위 =
    - 90%백분위수 =
    - (분산, 표준편차) =
  - 분포의 왜곡
    - 왜도=, 첨도=

- 시각화 분석 정리
  - 범주형 변수의 시각화
  - 수치형변수의 시각화
  - 왜곡된 변수를 전처리하는 방법(3가지)을 통해 histogram 만들기
    - ① 로그 변환 (Log Transformation)
    - ② 루트 변환 (Square Root Transformation)
    - ③ 박스-콕스 변환 (Box-Cox Transformation)

- **Tip) 관련 Excel 함수 : average, median, quartile, percentile, var, stdev, skew, kurt**
- **Kaggle에서 "EDA"를 검색하여 실습하기**

탐색적 데이터 분석(EDA, Exploratory Data Analysis) 보고서 작성 제출(3/3)

목차

1. 서론 (Introduction)

1.1 **분석 배경 및 목적:** 왜 이 데이터를 분석하는가? (비즈니스 문제 정의)

1.2 **데이터 셋 설명:** 출처, 기간, 데이터 수집 방법.

1.3 **주요 분석 질문(Key Questions):** 해결하고자 하는 가설 설정.

2. 데이터 프로파일링 및 기초 탐색 (Data Profiling)

2.1 **데이터 명세 확인:** 전체 레코드 수, 컬럼 수, 변수 타입(Dtype).

2.2 **결측치(Missing Value) 분석:** 결측 비율 시각화 및 발생 원인 추론.

결측치 처리 전략 (제거, 대체, 유지).

2.3 **기초 통계량 분석:** 평균, 중앙값, 분산, 사분위수 분석.

2.4 **데이터 정제(Cleaning) 결과:** 중복 제거, 자료형 변환, 이상치(Outlier) 정의 및 처리 결과.

3. 변수별 개별 특성 분석 (Univariate Analysis)

3.1 **수치형 변수 분석:**

분포의 왜도와 첨도 (정규성 검정).

히스토그램 및 밀도 함수(KDE) 분석.

3.2 **범주형 변수 분석:**

클래스별 빈도수 및 비율 분석.

희소 클래스(Rare labels) 존재 여부 확인.

3.3 **파생 변수 생성(Feature Engineering):** 범주 재그룹화(Binning).

4. 상관관계 및 관계 분석 (Multivariate Analysis)

4.1 **수치형 변수 간 상관관계:** 상관 계수 히트맵(Heatmap)을 통한 다중공선성 확인.

주요 변수 간 산점도(Scatter Plot) 및 추세선.

4.2 **타겟 변수 기반 심층 분석:** * 범주별 수치 분포 차이 (Box plot / Violin plot).

독립 변수들이 종속 변수에 미치는 영향력 시각화.

4.3 **세그먼트별 비교 분석:** 특정 조건(예: VIP 고객 vs 일반 고객)에 따른 행동 패턴 차이.

5. 핵심 인사이트 및 가설 검정 (Key Insights)

5.1 **주요 패턴 발견:** 시각화 결과에서 도출된 결정적 특징 요약.

5.2 **가설 검증 결과:** 1.3에서 설정한 가설의 채택/기각 여부.

5.3 **예상치 못한 발견(Unexpected Findings):** 초기 가설 외에 새롭게 발견된 특이 사항.

6. 결론 및 향후 방향 (Conclusion & Recommendation)

6.1 **분석 요약:** 전체 분석 프로세스의 핵심 요약.

6.2 **비즈니스 제언:** 발견된 인사이트를 토대로 한 실행 가능한 전략(Action Plan).

6.3 **한계점 및 추후 과제:** 데이터의 한계(샘플링 편향 등) 및 향후 머신러닝 모델 도입 가능성.